



**UNIVERSIDAD
SERGIO ARBOLEDA**

Detección de Anomalías en Imágenes Cervicales Utilizando Segmentación Semántica y Redes Convolucionales

**JHOSTIN SMITH ARISTIZABAL DÍAZ, ANDRES
CAMILO MORENO AMAYA, JUAN DIEGO
MUÑOZ BAQUERO**

UNIVERSIDAD SERGIO ARBOLEDA
ESCUELA DE CIENCIAS EXACTAS E INGENIERÍA
BOGOTÁ D.C.
2026

Detección de Anomalías en Imágenes Cervicales Utilizando Segmentación Semántica y Redes Convolucionales

JHOSTIN SMITH ARISTIZABAL DÍAZ, ANDRES
CAMILO MORENO AMAYA, JUAN DIEGO
MUÑOZ BAQUERO

PROYECTO DE GRADO

Asesor
Ricardo Andrés Fonseca Perdomo

UNIVERSIDAD SERGIO ARBOLEDA
ESCUELA DE CIENCIAS EXACTAS E INGENIERÍA
PREGRADO DE INGENIERÍA EN CIENCIAS DE LA COMPUTACIÓN E
INTELIGENCIA ARTIFICIAL
BOGOTÁ D.C.
2026



Contenido

Lista de tablas	6
1. Introducción	12
2. Estado del Arte	14
3. Marco Teórico	18
1. Cáncer Cervical	18
1.1. Definición y Epidemiología	18
1.2. Causas Biológicas y Factores de Riesgo	18
1.3. Clasificación Histológica	19
1.4. Diagnóstico Citológico: Prueba de Papanicolaou	19
1.5. Sistema de Clasificación de Bethesda	20
2. Procesamiento Digital de Imágenes Médicas	20
2.1. Fundamentos del Procesamiento de Imágenes	20
2.2. Preprocesamiento de Imágenes Citológicas	21
3. Aprendizaje Automático	24
3.1. Conceptos Fundamentales	24
3.2. Máquinas de Vectores de Soporte (SVM)	25
3.3. Redes Bayesianas	25
4. Aprendizaje Profundo (<i>Deep Learning</i>)	25
4.1. Redes Neuronales Artificiales	25
4.2. Redes Neuronales Convolucionales (CNN)	26
5. Transferencia de Aprendizaje	28
5.1. Fundamentos	28
5.2. Relevancia en Imágenes Médicas	28
6. Métodos de Ensamblado y Fusión de Modelos	29
6.1. Ensamblado de Clasificadores	29
6.2. Lógica Difusa aplicada a la Fusión de Predicciones	29
7. Selección de Características y Reducción de Dimensionalidad	30
7.1. Análisis de Componentes Principales (PCA)	30
7.2. Grey Wolf Optimizer (GWO)	30
8. Métricas de Evaluación en Clasificación	30
8.1. Curva ROC y Área Bajo la Curva (AUC-ROC)	31
8.2. Intersection over Union (IoU)	32
9. Conjuntos de Datos de Referencia en Citología Cervical	32
9.1. SIPaKMeD	32

9.2.	Herlev	32
9.3.	Mendeley LBC	33
4.	Problema de investigación	34
5.	Justificación	35
6.	Objetivos	36
1.	Objetivo general	36
2.	Objetivos específicos	36
7.	Metodología	37
1.	Aspectos principales de la metodología	37
2.	Método de investigación	37
3.	Población y muestra	38
4.	Método de adquisición de datos	39
5.	Proceso metodológico	40
8.	Desarrollo	44
1.	Descripción de los datasets	44
1.1.	SIPaKMeD	44
1.2.	Mendeley LBC	45
2.	Arquitectura del Entorno de Desarrollo	46
2.1.	Plataforma de Entrenamiento: Jupyter Notebook en Entorno Local	47
2.2.	Especificaciones del Hardware	47
2.3.	Arquitectura General del Flujo de Trabajo	49
3.	Configuración del Entorno de Software	50
4.	Pipeline de Preprocesamiento de Imágenes Citológicas	51
5.	Procesamiento de Máscaras de Segmentación	59
6.	Implementación de Modelos de Segmentación Semántica	61
6.1.	MMM U-Cervix	61
6.2.	U-Net con Spatial Dropout	63
6.3.	ResUNet (U-Net con Conexiones Residuales)	64
6.4.	YOLOv8 para Segmentación Semántica	65
9.	Resultados	67
1.	Métricas de evaluación	67
2.	Resultados individuales por modelo	68
2.1.	MMM U-Cervix (U-Net Baseline)	68
2.2.	ResUNet (U-Net con Conexiones Residuales)	70
2.3.	U-Net con Spatial Dropout	71
2.4.	YOLOv8-Seg	72
3.	Resultados generales	73
3.1.	Análisis comparativo	73

10. Conclusiones	75
1. Cumplimiento de objetivos	75
2. Hallazgos adicionales	76
3. Limitaciones del estudio	77
4. Trabajo futuro	77
5. Configuración del Entorno de Software	80



Lista de tablas

7.1. Variables, indicadores e instrumentos utilizados	42
8.1. Tipos celulares en el dataset SIPAKMED	45
8.2. Clases diagnósticas en el dataset Mendeley	46
8.3. Especificaciones de hardware del equipo de entrenamiento	48
8.4. Pipeline de procesamiento del proyecto	50
8.5. Bibliotecas principales del entorno de desarrollo	51
9.1. Métricas de evaluación — MMM U-Cervix	68
9.2. Métricas de evaluación — ResUNet	70
9.3. Métricas de evaluación — U-Net con Spatial Dropout	71
9.4. Métricas de evaluación — YOLOv8-Seg	72
9.5. Comparativa general de métricas de evaluación (conjunto de prueba) .	73
10.1. Frameworks de aprendizaje profundo	80
10.2. Dependencias internas de TensorFlow y Keras	81
10.3. Visión por computadora	82
10.4. Ciencia de datos y cómputo científico	83
10.5. Google APIs y protocolos de comunicación	84
10.6. Entorno Jupyter y notebooks interactivos (Parte 1)	85
10.7. Entorno Jupyter y notebooks interactivos (Parte 2)	86
10.8. HTTP, redes y comunicación asíncrona	87
10.9. Seguridad, criptografía y autenticación	88
10.10. Formatos de datos y serialización	89
10.11. Procesamiento web, HTML y plantillas	90
10.12. Análisis de código y depuración (IPython)	91
10.13. Kaggle y acceso a datos externos	92
10.14. Utilidades generales y compatibilidad	93

Glosario

- **CÁNCER CERVICAL:** enfermedad en la cual se desarrollan células malignas en el cuello uterino, frecuentemente asociada con la infección persistente por el virus del papiloma humano (VPH) [1].
- **CLAHE:** sigla de *Contrast Limited Adaptive Histogram Equalization*; es una técnica de mejora de contraste adaptativa que evita la amplificación excesiva del ruido al limitar la ganancia de histogramas en bloques locales [2].
- **DETECCIÓN DE ANOMALÍAS:** proceso mediante el cual se identifican patrones o eventos que se desvían significativamente del comportamiento esperado o normal en un conjunto de datos [3].
- **FILTRO BILATERAL:** técnica de filtrado no lineal que suaviza la imagen preservando los bordes, considerando tanto la distancia espacial como la diferencia de intensidad de los píxeles [4].
- **PROCESAMIENTO DE IMÁGENES:** conjunto de técnicas que permiten transformar, analizar o mejorar imágenes digitales con el objetivo de extraer información o facilitar su interpretación [5].
- **REDES CONVOLUCIONALES:** tipo de red neuronal profunda especializada en procesamiento de datos con estructura de cuadrícula, como imágenes, que utiliza filtros convolucionales para detectar características jerárquicas [6].
- **REDES U-NET:** arquitectura de red neuronal convolucional diseñada específicamente para tareas de segmentación de imágenes biomédicas, caracterizada por su forma de U simétrica con etapas de contracción y expansión [7].
- **SEGMENTACIÓN SEMÁNTICA:** proceso mediante el cual se asigna una etiqueta a cada píxel de una imagen, de modo que se identifiquen regiones coherentes que representan objetos o clases específicas [6].
- **CNN (RED NEURONAL CONVOLUCIONAL):** arquitectura de aprendizaje profundo compuesta por capas convolucionales que permiten extraer y aprender características espaciales de las imágenes de manera jerárquica [6].
- **CONTRASTE LOCAL:** variación de intensidad en regiones pequeñas de una imagen; su mejora permite resaltar detalles sutiles que pueden ser clínicamente relevantes [2].

- **DETECCIÓN AUTOMÁTICA:** proceso computacional mediante el cual un sistema identifica patrones, estructuras o eventos de interés sin intervención humana directa, común en sistemas de diagnóstico asistido [3].
- **EXTRACCIÓN DE CARACTERÍSTICAS:** etapa del procesamiento de imágenes donde se obtienen descriptores relevantes que representan información estructural, morfológica o de textura útil para clasificación [5].
- **IMAGEN CITOLÓGICA:** imagen obtenida mediante microscopía de una muestra celular, utilizada para el análisis de morfología celular con fines diagnósticos [1].
- **MORFOLOGÍA CELULAR:** conjunto de características estructurales y de forma que presentan las células, tales como tamaño, contorno, relación núcleo-citoplasma, entre otras [1].
- **PREPROCESAMIENTO:** conjunto de técnicas aplicadas antes del análisis o entrenamiento del modelo, que tienen como objetivo mejorar la calidad de la imagen o estandarizarla para la siguiente etapa del flujo [5].
- **VIRUS DEL PAPILOMA HUMANO (VPH):** virus de transmisión sexual que se asocia con la mayoría de los casos de cáncer cervical; su detección temprana y monitoreo son esenciales en programas de tamizaje [1].
- **IoU (INTERSECTION OVER UNION):** métrica estándar en visión por computador que evalúa el grado de solapamiento entre regiones mediante el cociente entre el área de intersección y la unión, utilizada en segmentación y detección de objetos [8].
- **F1-SCORE:** medida de desempeño que combina precisión y recall mediante la media armónica, útil para evaluar modelos en datasets desbalanceados [9].
- **AUC-ROC:** área bajo la curva ROC (Receiver Operating Characteristic), que evalúa la capacidad de un modelo para discriminar entre clases a través de todos los umbrales posibles, representando la relación entre la tasa de verdaderos positivos y falsos positivos [10].
- **ESPACIO DE COLOR LAB:** modelo de color perceptualmente uniforme que separa la luminancia (L) de los componentes cromáticos (A y B), facilitando el procesamiento de imágenes al permitir ajustes de contraste sin alterar la información de color [11].
- **NON-LOCAL MEANS (NLM):** algoritmo de reducción de ruido que estima el valor de un píxel mediante el promedio ponderado de píxeles similares en toda la imagen, preservando estructuras finas y texturas [12].

- **CONEXIONES DE SALTO (SKIP CONNECTIONS):** mecanismo arquitectónico que permite la propagación directa de información entre capas no consecutivas en redes neuronales, facilitando la recuperación de detalles espaciales al combinar características de bajo y alto nivel, como en U-Net [7].
- **RESIDUALES:** conexiones que permiten la propagación directa de información entre capas no consecutivas en redes neuronales, facilitando la recuperación de detalles espaciales al combinar características de bajo y alto nivel, como en U-Net [7].
- **SPATIAL DROPOUT:** técnica de regularización que consiste en eliminar neuronas de manera aleatoria en capas convolucionales, con el objetivo de evitar el sobreajuste en redes neuronales [5].

Resumen

Este proyecto aborda la detección de anomalías en imágenes citológicas cervicales, problemática caracterizada por la alta variabilidad en la apariencia celular, la presencia de ruido y la dependencia de evaluaciones manuales propensas a subjetividad y errores. En este contexto, se identificó la limitada robustez de los métodos automáticos de segmentación frente a condiciones no ideales de adquisición de imagen. Para mitigar estas limitaciones, se propuso un enfoque basado en la integración de técnicas avanzadas de preprocesamiento de imágenes y modelos de aprendizaje profundo.

A partir de esta base, se diseñó y desarrolló un flujo de preprocesamiento orientado a optimizar la calidad visual y resaltar estructuras celulares relevantes. Este incluyó técnicas de realce de contraste local, filtrado no lineal para reducción de ruido con preservación de bordes, y operaciones morfológicas para mejorar la definición de regiones de interés. Como resultado, se logró una representación más específica de las características celulares, facilitando su posterior análisis.

Sobre estas imágenes preprocesadas, se aplicaron modelos de segmentación semántica basados en arquitecturas tipo U-Net, junto con comparaciones frente a otros enfoques basados en redes convolucionales, incluyendo YOLOv8-Seg, un modelo originalmente diseñado para detección de objetos pero utilizado en este trabajo bajo el enfoque de segmentación de objetos. Los resultados evidencian que el preprocesamiento propuesto tuvo un impacto significativo en el rendimiento del sistema, permitiendo alcanzar valores superiores al 90 % en métricas de evaluación como F1-Score e Intersection over Union (IoU). Esto demuestra una mejora sustancial en la precisión con respecto a enfoques sin preprocesamiento o con técnicas convencionales.

En conjunto, los resultados obtenidos validan la importancia del preprocesamiento como etapa crítica en sistemas de análisis de imágenes médicas, al potenciar la capacidad de los modelos de aprendizaje profundo para segmentar estructuras celulares complejas y contribuir al diagnóstico temprano de anomalías cervicales.

palabras clave: segmentación semántica, preprocesamiento de imágenes, cáncer cervical, redes convolucionales, U-Net, YOLOv8-Seg, F1-Score, IoU.

Abstract

This project addresses the detection of anomalies in cervical cytological images, a problem characterized by high variability in cellular appearance, the presence of noise, and reliance on manual evaluations prone to subjectivity and errors. In this context, the limited robustness of automatic segmentation methods under non-ideal image acquisition conditions was identified. To mitigate these limitations, an approach based on the integration of advanced image preprocessing techniques and deep learning models was proposed.

Based on this foundation, a preprocessing pipeline was designed and developed to optimize visual quality and highlight relevant cellular structures. This included local contrast enhancement techniques, non-linear filtering for noise reduction with edge preservation, and morphological operations to improve the definition of regions of interest. As a result, a more discriminative representation of cellular features was achieved, facilitating subsequent analysis.

On these preprocessed images, semantic segmentation models based on U-Net architectures were applied, along with comparisons against other convolutional approaches, including YOLOv8-Seg, a model originally designed for object detection but adapted here for object segmentation tasks. The results show that the proposed preprocessing had a significant impact on system performance, achieving values above 90% in evaluation metrics such as F1-Score and Intersection over Union (IoU). This demonstrates a substantial improvement in accuracy compared to approaches without preprocessing or with conventional techniques.

Overall, the obtained results validate the importance of preprocessing as a critical stage in medical image analysis systems, enhancing the ability of deep learning models to segment complex cellular structures and contributing to the early diagnosis of cervical anomalies.

keywords: semantic segmentation, image preprocessing, cervical cancer, convolutional neural networks, U-Net, YOLOv8-Seg, F1-Score, IoU.

Introducción

El cáncer de cuello uterino también conocido como cáncer cervical es el cuarto tipo de cáncer más común en mujeres a nivel mundial, con aproximadamente 600 mil nuevos casos reportados en 2022. De estos, más del 94 % de las 350 mil muertes asociadas ocurrieron en países de ingresos bajos y medianos [13]. En el ámbito clínico, la citología cervical, comúnmente realizada mediante la prueba de Papanicolaou, continúa siendo el método estándar para la detección de lesiones precancerosas [14].

A pesar de su amplio uso, la interpretación de estas pruebas presenta limitaciones inherentes vinculadas a la evaluación subjetiva. Esta dependencia no solo impacta al personal clínico, sino también a las pacientes y a los sistemas de salud, especialmente en contextos con recursos limitados donde el acceso a especialistas es restringido. En este contexto, surge la necesidad de desarrollar métodos automatizados que permitan mejorar la precisión, reproducibilidad y eficiencia en el análisis citológico [15].

En los últimos años, diversas investigaciones han explorado la aplicación de técnicas de visión por computador y aprendizaje profundo para abordar este problema. En particular, se han propuesto enfoques que combinan extracción de características con redes neuronales convolucionales (CNN) y algoritmos de optimización, mostrando un alto desempeño en tareas de clasificación de imágenes cervicales [16], [17], [18].

Un ejemplo representativo es el trabajo de Basak et al., quienes desarrollaron un sistema automatizado basado en arquitecturas como ResNet-50 y VGG-16 para la extracción de características profundas, seguido de reducción de dimensionalidad mediante Análisis de Componentes Principales (PCA) y optimización con el algoritmo Grey Wolf Optimizer (GWO), alcanzando tasas de precisión superiores al 98 % en múltiples conjuntos de datos públicos [19].

Sin embargo, la mayoría de estos enfoques se centran en la clasificación directa de imágenes completas, sin abordar explícitamente el problema de la segmentación celular, el cual resulta fundamental para una localización precisa de estructuras anómalas. Aunque existen métodos tradicionales de segmentación, como técnicas basadas en clustering difuso o contornos activos, estos presentan limitaciones en términos de precisión y robustez frente a la alta variabilidad y complejidad de las imágenes citológicas reales [17], [19].

Adicionalmente, estos enfoques suelen asumir condiciones de entrada ideales, sin considerar de manera explícita el impacto del preprocesamiento en la calidad de las representaciones utilizadas por los modelos, lo que limita su desempeño en escenarios reales. En este sentido, a diferencia de los enfoques convencionales centrados en el diseño de arquitecturas, en esta investigación se propone una estrategia que posiciona el preprocesamiento como factor determinante en el desempeño de los modelos de segmentación.

Desde una perspectiva de procesamiento de imágenes, la calidad de la información de entrada juega un papel determinante en el desempeño de los modelos de aprendizaje profundo, particularmente en tareas de segmentación semántica donde la localización precisa depende de la preservación de bordes y estructuras finas [5]. En este contexto, el preprocesamiento no solo actúa como una etapa de mejora visual, sino como un mecanismo de transformación del espacio de características que puede incrementar la separabilidad entre clases y reducir la influencia del ruido en las imágenes citológicas [12]. Este aspecto resulta especialmente relevante en entornos biomédicos, donde las condiciones de adquisición no siempre son controladas y la variabilidad intrínseca de las muestras representa un desafío significativo para los modelos de segmentación [7].

Bajo esta premisa, evaluar el impacto del preprocesamiento sobre múltiples arquitecturas permite no solo cuantificar mejoras en términos de desempeño, sino también analizar la consistencia de dichas mejoras frente a diferentes enfoques de modelado. Esta perspectiva experimental facilita distinguir si las ganancias obtenidas provienen del diseño del modelo o de la calidad de los datos de entrada, aportando evidencia sobre la relevancia del preprocesamiento como un componente transversal en sistemas de segmentación.

La metodología adoptada comprende tres fases secuenciales: adquisición y preparación del corpus de imágenes cervicales, diseño e implementación de un pipeline de preprocesamiento basado en CLAHE, filtrado bilateral y operaciones morfológicas [2], [4], y evaluación sistemática del impacto de dicho preprocesamiento sobre múltiples arquitecturas de segmentación semántica.

El desempeño de cada configuración se cuantifica mediante las métricas Intersection over Union (IoU) y F1-score, calculadas sobre conjuntos de validación y prueba independientes. Este esquema permite determinar si las mejoras en la representación de entrada son consistentes con independencia del diseño arquitectónico empleado.

Estado del Arte

El avance en el diagnóstico automatizado del cáncer cervical ha sido impulsado por el desarrollo de técnicas de aprendizaje profundo y procesamiento de imágenes, que buscan superar las limitaciones del análisis citológico manual. Los estudios revisados se agrupan en cuatro líneas de trabajo: enfoques de ensamblado y fusión de modelos profundos, métodos basados en selección de características y optimización, propuestas desarrolladas en contextos latinoamericanos con recursos limitados, y aplicaciones de transferencia de aprendizaje en imágenes médicas.

Pramanik, Sengupta y Sural [20] proponen un sistema de clasificación citológica basado en el ensamblado difuso de tres modelos de transferencia de aprendizaje: Inception V3, MobileNet V2 e Inception ResNet V2. La fusión de sus predicciones se realiza mediante medidas de distancia euclidiana, Manhattan y coseno, combinadas con una regla de mecanismo de agregación difusa (proceso de conversión de salidas difusas a una decisión concreta), lo que permite integrar las fortalezas de cada modelo en una decisión unificada.

El sistema alcanzó una precisión del 96.96 %, superando el desempeño de los modelos individuales. Sin embargo, la arquitectura de ensamblado incrementa la complejidad computacional y no aborda explícitamente las condiciones de preprocesamiento de imagen, lo que puede limitar su robustez ante la variabilidad en la calidad de las muestras [20].

En una línea similar, Ghosh et al. [18] desarrollaron un sistema de diagnóstico asistido por computadora basado en el ensamblado de Inception V3, Xception y DenseNet-169, cuyas predicciones se combinan mediante un esquema de ranking difuso que pondera la confianza de cada clasificador base. El sistema fue evaluado sobre los conjuntos de datos SIPaKMeD y Mendeley LBC.

Los resultados alcanzaron precisiones de hasta el 99.23 %, posicionando este enfoque entre los más competitivos reportados en la literatura. No obstante, la dependencia de múltiples arquitecturas de gran escala eleva los requerimientos de memoria y cómputo, y el estudio no discute estrategias de adaptación a entornos clínicos con infraestructura limitada [18].

Islam et al. [21] introdujeron *DeepCervix*, un sistema de fusión híbrida de características profundas (*Hybrid Deep Feature Fusion*, HDFF) que supera la necesidad de

segmentación precisa previa a la clasificación. A diferencia de enfoques anteriores, el modelo no depende de características extraídas manualmente, lo que reduce la intervención humana en el proceso.

Evaluable en los conjuntos SIPaKMeD y Herlev, *DeepCervix* logró precisiones de hasta el 99.85 % en tareas binarias y multiclase. A pesar de su alto rendimiento, el estudio no analiza el comportamiento del modelo frente a imágenes con artefactos de tinción o baja resolución, condiciones frecuentes en laboratorios con recursos restringidos [21].

Basak et al. [19] proponen un sistema automatizado que combina la extracción de características profundas mediante redes neuronales convolucionales con reducción de dimensionalidad por Análisis de Componentes Principales (PCA), preservando el 99 % de la varianza. Sobre este subespacio de características, el algoritmo *Grey Wolf Optimizer* (GWO) selecciona el subconjunto más discriminativo para alimentar un clasificador SVM.

Evaluable en tres conjuntos de datos públicos, el sistema superó el 97 % de precisión. Sin embargo, la pipeline depende de una etapa de extracción de características bien definida y no contempla mecanismos de normalización de imagen, lo que puede afectar la estabilidad del clasificador ante muestras de distinta procedencia [19].

En el estudio de [22] se propone un enfoque alternativo centrado exclusivamente en los rasgos morfológicos y de textura del núcleo celular, prescindiendo del análisis del citoplasma. Se evaluaron algoritmos clásicos de clasificación como SVM, k-NN, árboles de decisión (C4.5), regresión logística y perceptrón multicapa (MLP), comparando su rendimiento bajo las mismas condiciones de entrada.

Los resultados demostraron que los atributos morfológicos y de textura son suficientes para distinguir entre células normales y anómalas. No obstante, al ignorar el citoplasma se descarta información estructural que puede ser diagnósticamente relevante en lesiones avanzadas, lo que limita la generalización del enfoque a clasificaciones multiclase [22].

Salinas et al. [23] analizaron 400 descriptores MAC (Cambios Asociados a Malignidad) reportados en la literatura para la detección de cambios malignos en células cervicales, evaluando su capacidad discriminativa mediante un clasificador de redes bayesianas. El estudio fue publicado en la Revista Cubana de Ciencias Informáticas y destaca por su pertinencia en contextos con infraestructura computacional limitada.

La precisión alcanzada fue del 86.94 %, inferior a los enfoques basados en aprendizaje profundo, pero relevante por su interpretabilidad y bajo costo computacional. El estudio subraya la importancia de estandarizar los descriptores empleados en la literatura, dado que la heterogeneidad en su definición dificulta la comparación entre sistemas [23].

En [24], Ciro et al. propone un sistema basado en redes neuronales convolucionales entrenado con imágenes categorizadas por expertos en tres clases: células sanas, L-SIL y H-SIL. El objetivo fue desarrollar una herramienta de detección temprana que automatizara el análisis citológico, reduciendo la carga del personal médico en entornos clínicos colombianos.

A pesar del planteamiento, el modelo no superó el 80 % de precisión, lo que los propios autores reconocen como insuficiente para uso clínico confiable. Esta limitación se atribuye parcialmente a la ausencia de etapas de preprocesamiento que normalicen la calidad de las imágenes de entrada y la implementación de un modelo de clasificación simple [24].

Otra aproximación es la presentada por Bravo-Ortíz et al. [25] quienes presentaron en la Revista EIA una metodología para clasificar el tipo de cáncer cervical —leve o agresivo— mediante redes neuronales convolucionales combinadas con técnicas de aumento de datos y transferencia de aprendizaje. Este enfoque está orientado a compensar la escasez de datos etiquetados, una limitación frecuente en entornos clínicos de la región.

El modelo alcanzó una precisión de hasta el 97.35 % en validación, consolidándose como un referente metodológico en el contexto latinoamericano. Sin embargo, el estudio se centra en la clasificación binaria de severidad y no aborda la segmentación celular ni el preprocesamiento de imagen como factores de mejora [25].

Flores et al. [26] compararon el rendimiento de modelos sin transferencia de aprendizaje CNN, DenseNet121 y SVM con extracción de características sobre un conjunto de 4049 imágenes de Papanicolaou. Se evaluaron tanto métricas de rendimiento diagnóstico como el consumo de recursos computacionales, con el fin de identificar la solución más eficiente para entornos con capacidad de cómputo restringida.

El modelo CNN con dropout obtuvo los mejores resultados con una precisión, exactitud y F1-score del 90 %, 90.5 % y 90.5 % respectivamente. El estudio concluye que es posible alcanzar desempeños competitivos sin recurrir a arquitecturas complejas, aunque reconoce que la calidad del preprocesamiento de imagen es un factor determinante para la estabilidad de los resultados [26].

Por otro lado, en [27], Ruiz exploró el uso de modelos de aprendizaje profundo sobre imágenes de Tomosíntesis Digital 3D (DBT) para la detección y clasificación de tumores mamarios. Si bien el dominio de aplicación difiere del análisis citológico cervical, el estudio aporta evidencia metodológica relevante sobre el uso de YOLOv5x con aumento de datos y transferencia de aprendizaje en conjuntos de datos limitados.

El modelo logró una precisión del 84 %, un recall del 93 % y un mAP del 97 %, demostrando que la transferencia de aprendizaje permite alcanzar rendimientos competitivos incluso con datos escasos. Esta evidencia respalda la aplicabilidad de estrategias similares en tareas de segmentación y clasificación de células cervicales, donde los conjuntos de datos etiquetados también son limitados [27].

La revisión de los estudios anteriores evidencia que los enfoques basados en aprendizaje profundo han alcanzado precisiones notables en la clasificación de células cervicales. Sin embargo, la mayoría asume condiciones de imagen homogéneas y no incorpora etapas explícitas de preprocesamiento. Esta omisión limita la transferibilidad de los modelos a entornos clínicos donde la variabilidad en tinción, contraste y resolución es inherente al proceso de adquisición, y constituye la brecha que orienta la presente investigación (véase Cap. 1).

Marco Teórico

Este capítulo expone los fundamentos conceptuales y científicos que sustentan el estudio. Se aborda en primer lugar el contexto clínico del cáncer cervical, seguido de los principios del procesamiento digital de imágenes médicas, las bases del aprendizaje automático y profundo, y finalmente los mecanismos específicos de las arquitecturas empleadas en la clasificación citológica.

1. Cáncer Cervical

1.1. Definición y Epidemiología

El cáncer cervical, o cáncer de cuello uterino, es un tumor maligno que se origina en las células del epitelio del cuello uterino, particularmente en la zona de transformación, una región de alta actividad celular donde convergen dos tipos de epitelio: el escamoso (que recubre la vagina) y el glandular (que reviste el canal cervical). Debido a la actividad celular de la zona de transformación, es donde se presentan la mayoría de las lesiones precancerosas y cancerosas. Cabe resaltar que el cáncer de cuello uterino es uno de los tumores ginecológicos más frecuentes a nivel mundial y representa un problema de salud pública de primera magnitud [28].

1.2. Causas Biológicas y Factores de Riesgo

La infección por el Virus del Papiloma Humano (VPH) es la principal causa de cáncer cervical, responsable de más del 99 % de los casos. El VPH comprende más de 200 variantes (genotipos); de ellas, los tipos 16 y 18 se clasifican como de *alto riesgo oncogénico* y explican aproximadamente el 70 % de los casos de cáncer cervical. Su mecanismo de acción es molecular: las proteínas virales E6 y E7 —codificadas por los oncogenes del virus— bloquean a p53 y pRb, dos proteínas que actúan como reguladores del ciclo celular. Al inhabilitarlas, la célula pierde el control sobre su propia replicación, lo que desencadena una proliferación celular descontrolada [29].

Entre los factores de riesgo asociados figuran el inicio temprano de la actividad sexual, el número elevado de compañeros sexuales, el tabaquismo, el uso prolongado de anticonceptivos orales, la inmunosupresión y la coinfección por otras infecciones de transmisión sexual.

1.3. Clasificación Histológica

Histológicamente, el cáncer cervical se clasifica principalmente en dos subtipos: el carcinoma epidermoide o escamocelular, que representa entre el 70 % y el 80 % de los casos, y el adenocarcinoma, que constituye entre el 15 % y el 25 % restante. Existen formas mixtas y variantes menos frecuentes.

Para la estadificación, se emplea el sistema de la Federación Internacional de Ginecología y Obstetricia (FIGO), actualizado en 2018, que clasifica la enfermedad en cuatro estadios según la extensión del tumor: estadio I (confinado al cuello uterino), estadio II (extensión más allá del cuello), estadio III (compromiso de la pared pélvica o tercio inferior de la vagina) y estadio IV (extensión a órganos adyacentes o metástasis a distancia). El pronóstico varía considerablemente según el estadio al momento del diagnóstico, con tasas de supervivencia a cinco años que oscilan entre el 93 % en estadio IA y el 15 % en estadio IVB [30].

1.4. Diagnóstico Citológico: Prueba de Papanicolaou

La prueba de Papanicolaou (PAP), introducida en la década de 1940, constituye el método de referencia para la detección precoz de lesiones precancerosas cervicales. El procedimiento consiste en la recolección de células exfoliadas de la zona de transformación, su fijación química sobre portaobjetos y su posterior procesamiento para análisis microscópico.

La tinción de Papanicolaou aplica una combinación de hematoxilina, eosina y naranja de acridina para generar contraste cromático diferencial entre el núcleo y el citoplasma celular. Este contraste hace observable la morfología nuclear bajo microscopía óptica y constituye la base visual sobre la que el citopatólogo realiza la interpretación diagnóstica.

La interpretación de la muestra por parte del citopatólogo permite identificar alteraciones en la morfología celular asociadas a infección por VPH, displasias de diverso grado o carcinoma.

No obstante, la prueba presenta limitaciones inherentes como la sensibilidad variable (entre el 50 % y el 70 % según las series), la dependencia de la calidad de la muestra obtenida y, fundamentalmente, la alta carga de trabajo sobre el personal especializado, a pesar de su eficacia demostrada en la reducción de la mortalidad por cáncer cervical cuando se implementa en programas de tamizaje poblacional [31].

1.5. Sistema de Clasificación de Bethesda

El Sistema de Bethesda (TBS, *The Bethesda System*), propuesto en 1988 y revisado en 1991, 2001 y 2014, es el marco de nomenclatura estandarizado para la comunicación de resultados en citología cervical. Su adopción a nivel internacional ha permitido homogeneizar el lenguaje diagnóstico entre instituciones y mejorar la reproducibilidad interpretativa.

Las categorías principales de este sistema son:

- **NILM** (*Negative for Intraepithelial Lesion or Malignancy*): células dentro de límites normales, sin evidencia de lesión intraepitelial o malignidad.
- **ASC-US** (*Atypical Squamous Cells of Undetermined Significance*): células escamosas atípicas de significado indeterminado.
- **ASC-H** (*Atypical Squamous Cells, cannot exclude HSIL*): células escamosas atípicas que no permiten descartar lesión de alto grado.
- **L-SIL** (*Low-grade Squamous Intraepithelial Lesion*): lesión intraepitelial escamosa de bajo grado, que incluye cambios por VPH y displasia leve (NIC I).
- **H-SIL** (*High-grade Squamous Intraepithelial Lesion*): lesión intraepitelial escamosa de alto grado, que comprende la displasia moderada (NIC II) y la displasia severa/carcinoma in situ (NIC III).
- **Carcinoma escamocelular y adenocarcinoma**: categorías correspondientes a malignidad franca [32].

La clasificación L-SIL/H-SIL resulta de especial relevancia para los sistemas automatizados de análisis citológico, dado que constituye la base categórica sobre la que se entrenan los modelos de clasificación supervisada utilizados en la investigación actual.

2. Procesamiento Digital de Imágenes Médicas

2.1. Fundamentos del Procesamiento de Imágenes

Una imagen digital puede definirse formalmente como una función discreta $f : \mathbb{Z}^2 \rightarrow \mathbb{R}^k$, donde cada par de coordenadas (x, y) representa un píxel cuyo valor corresponde a la intensidad luminosa en el caso de imágenes en escala de grises ($k = 1$) o a un vector de componentes espectrales en el caso de imágenes a color ($k = 3$ para el modelo RGB) [5].

El procesamiento digital de imágenes agrupa un conjunto de operaciones matemáticas cuyo objetivo es transformar la representación original de una imagen para extraer información relevante, reducir el ruido, realzar características de interés o preparar la

imagen para etapas de análisis posterior. En el contexto de imágenes histológicas y citológicas, este tipo de procesamiento reviste particular importancia dado que la calidad de la muestra y las condiciones de adquisición introducen variabilidad que puede degradar el desempeño de los clasificadores automáticos.

2.2. Preprocesamiento de Imágenes Citológicas

El preprocesamiento constituye la primera etapa de cualquier *pipeline* de análisis automatizado de imágenes médicas y tiene como finalidad normalizar y homogeneizar las características de las muestras antes de su presentación al modelo de clasificación. Las principales operaciones de preprocesamiento aplicables a imágenes de citología cervical se describen a continuación.

Normalización de la Tinción

Las imágenes de citología teñidas con la coloración de Papanicolaou presentan variaciones significativas en el perfil cromático según el tipo de colorante utilizado, las condiciones del laboratorio, el tiempo de fijación y el sistema de digitalización empleado. La normalización de la tinción (*stain normalization*) tiene como objetivo transformar las imágenes hacia una referencia cromática común, reduciendo la variabilidad de color.

Los métodos clásicos operan en el espacio de color HSV que descompone la imagen en sus componentes de Tono, Saturación y Valor, permitiendo ajustar cada componente de forma independiente para mejorar el contraste y la calidad de la imagen.

Ajuste de Contraste y Ecualización del Histograma

El contraste de una imagen se define como la diferencia de intensidad entre las regiones de mayor y menor brillo. En imágenes citológicas, un contraste insuficiente puede dificultar la discriminación entre el núcleo y el citoplasma celular, dos regiones de interés diagnóstico primordial.

La ecualización del histograma es una técnica que redistribuye los niveles de intensidad de la imagen de forma que el histograma resultante se aproxime a una distribución uniforme, mejorando el contraste global. La variante adaptativa CLAHE (*Contrast Limited Adaptive Histogram Equalization*) aplica esta operación de forma localizada sobre bloques de la imagen, con un límite en el factor de amplificación para evitar la sobreintensificación del ruido [2].

Espacio de Color LAB

El espacio de color CIE LAB (también escrito $L^*a^*b^*$), estandarizado por la Comisión Internacional de Iluminación [11], es un modelo perceptualmente uniforme que separa

2. Procesamiento Digital de Imágenes Médicas

la información de luminancia del componente cromático. Sus tres canales son:

- L : luminancia, con rango $[0, 100]$ de negro a blanco.
- a : oposición rojo-verde, con valores negativos hacia el verde y positivos hacia el rojo.
- b : oposición azul-amarillo, con valores negativos hacia el azul y positivos hacia el amarillo.

La principal ventaja de este espacio para el preprocesamiento de imágenes citológicas es que permite ajustar el contraste del canal L de forma independiente a la cromaticidad, evitando la distorsión de tinción durante la ecualización. En concreto, la aplicación de CLAHE sobre el canal L en el espacio LAB mejora la visibilidad de estructuras celulares finas sin alterar la información cromática que distingue el núcleo del citoplasma [33].

Reducción de Ruido y Filtrado

El ruido en imágenes citológicas puede originarse en el proceso de digitalización, en artefactos de preparación de la muestra o en imperfecciones del sistema óptico. Los filtros frecuentemente empleados para su atenuación incluyen:

- **Filtro Gaussiano**: convuelve la imagen con un núcleo de distribución normal, produciendo un suavizado isotrópico que preserva las transiciones graduales.
- **Filtro de mediana**: reemplaza cada píxel por la mediana de los valores en su vecindad, siendo especialmente efectivo frente al ruido impulsivo o *sal y pimienta*.
- **Filtro bilateral**: combina la proximidad espacial y la similitud de intensidad como criterios de ponderación, logrando la reducción del ruido con preservación de bordes.

Non-Local Means (NLM)

El algoritmo *Non-Local Means* (NLM), introducido por Buades et al. [12], es una técnica de reducción de ruido que estima el valor restaurado de cada píxel como una media ponderada de *todos* los píxeles de la imagen (o de una región de búsqueda), asignando mayor peso a aquellos cuya vecindad local sea más similar a la del píxel objetivo:

$$\text{NL}[u](x) = \frac{1}{\mathcal{C}(x)} \int_{\Omega} w(x, y) u(y) dy \quad (3.1)$$

donde $w(x, y) = \exp\left(-\frac{\|u(N_x) - u(N_y)\|_{2,a}^2}{h^2}\right)$ es el peso basado en la similitud entre las vecindades N_x y N_y de los píxeles x e y , h es un parámetro de suavizado y $\mathcal{C}(x)$ es la constante de normalización.

A diferencia del filtro Gaussiano o el bilateral —que solo consideran la vecindad inmediata—, NLM aprovecha la redundancia estructural de la imagen completa, lo que le permite preservar texturas finas y bordes con mayor fidelidad. Esta propiedad es especialmente valiosa en imágenes citológicas de alta resolución, donde la textura nuclear constituye un descriptor diagnóstico relevante que no debe degradarse durante la etapa de filtrado.

Segmentación Celular

La segmentación es el proceso de partición de la imagen en regiones con significado semántico diferenciado. En citología cervical, las regiones de interés primordiales son el núcleo celular y el citoplasma, cuya delimitación precisa constituye la base para la extracción de características morfológicas y la clasificación posterior.

Los métodos de segmentación pueden clasificarse en técnicas basadas en umbralización (Otsu, umbralización adaptativa), métodos de crecimiento de región, contornos activos (*snakes*) y, en las aproximaciones más recientes, arquitecturas de segmentación semántica basadas en redes neuronales profundas como U-Net [7], que han demostrado desempeños superiores a los métodos clásicos en tareas de segmentación de estructuras celulares.

Arquitectura U-Net para Segmentación Biomédica

U-Net [7] es una arquitectura de red neuronal convolucional diseñada específicamente para la segmentación semántica de imágenes biomédicas con conjuntos de datos reducidos. Su estructura simétrica en forma de «U» comprende dos trayectorias:

1. **Trayectoria de contracción** (*encoder*): secuencia de bloques convolucionales seguidos de operaciones de max-pooling que reducen progresivamente la resolución espacial y aumentan el número de mapas de características, extrayendo representaciones semánticas de alto nivel.
2. **Trayectoria de expansión** (*decoder*): secuencia de operaciones de convolución traspuesta (o interpolación bilineal) que recuperan progresivamente la resolución espacial, combinando en cada nivel las características descomprimidas con las correspondientes de la trayectoria de contracción mediante **conexiones de salto** (*skip connections*).

Las conexiones de salto concatenan los mapas de características del encoder con los del decoder a igual resolución espacial, permitiendo que la red recupere detalles de localización fina que se pierden durante el proceso de submuestreo. Formalmente, la característica de entrada de cada nivel del decoder es:

$$\mathbf{f}_{\text{dec}}^{(l)} = \text{Conv}\left(\left[\text{Up}\left(\mathbf{f}_{\text{dec}}^{(l+1)}\right), \mathbf{f}_{\text{enc}}^{(l)}\right]\right) \quad (3.2)$$

donde $[\cdot, \cdot]$ denota la concatenación por canales y $\text{Up}(\cdot)$ la operación de upsample.

Esta arquitectura ha establecido un referente en segmentación de estructuras celulares y nucleares, habilitando la delimitación precisa del núcleo y el citoplasma requerida como preprocesamiento de los clasificadores de células cervicales descritos en el estado del arte.

Aumento de Datos (*Data Augmentation*)

El aumento de datos es una estrategia de regularización que amplía artificialmente el conjunto de entrenamiento mediante la aplicación de transformaciones geométricas y fotométricas reversibles a las imágenes originales. Las transformaciones típicas incluyen rotaciones, traslaciones, volteos horizontales y verticales, escala, recortes aleatorios (*random crop*), cambios de brillo y contraste, y adición de ruido gaussiano.

Esta técnica adquiere especial relevancia en el análisis de imágenes médicas, donde los conjuntos de datos etiquetados son escasos por la alta especialización requerida para la anotación. El aumento de datos reduce el sobreajuste del modelo y mejora su capacidad de generalización frente a variaciones no vistas durante el entrenamiento [34].

3. Aprendizaje Automático

3.1. Conceptos Fundamentales

El aprendizaje automático (*machine learning*) es una rama de la inteligencia artificial que estudia el desarrollo de algoritmos capaces de aprender patrones a partir de datos empíricos, sin ser programados explícitamente para cada tarea. Su fundamento formal radica en la teoría del aprendizaje estadístico: dado un espacio de hipótesis $\mathcal{H}$ y un conjunto de entrenamiento $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^n$, el objetivo es encontrar la función $h \in \mathcal{H}$ que minimice el riesgo esperado $R(h) = \mathbb{E}[\mathcal{L}(h(x), y)]$, donde $\mathcal{L}$ es una función de pérdida que cuantifica el error de predicción [35].

Según el tipo de supervisión disponible, los paradigmas principales son:

- **Aprendizaje supervisado:** el modelo se entrena con pares (x_i, y_i) donde y_i es la etiqueta conocida. Es el paradigma dominante en clasificación de imágenes médicas.

- **Aprendizaje no supervisado:** el modelo descubre estructura latente en los datos sin etiquetas, como en agrupamiento o reducción de dimensionalidad.
- **Aprendizaje semisupervisado:** aprovecha tanto datos etiquetados como no etiquetados, estrategia relevante cuando el etiquetado es costoso.

3.2. Máquinas de Vectores de Soporte (SVM)

Las Máquinas de Vectores de Soporte (*Support Vector Machines*, SVM), introducidas por Vapnik y Cortes en 1995, son clasificadores discriminativos que determinan el hiperplano de separación óptimo entre clases, maximizando el margen de separación entre los ejemplos de entrenamiento más próximos al hiperplano (vectores de soporte). Para problemas no linealmente separables, emplean el *truco del kernel*, que mapea implícitamente los datos a un espacio de mayor dimensión donde sí resultan separables [36].

Las SVM han sido ampliamente empleadas en clasificación de células cervicales, frecuentemente combinadas con etapas previas de extracción de características manuales o automáticas mediante redes neuronales convolucionales.

3.3. Redes Bayesianas

Una red bayesiana es un modelo gráfico probabilístico que representa las relaciones de dependencia condicional entre variables aleatorias mediante un grafo acíclico dirigido (DAG). Cada nodo representa una variable y cada arista una relación de dependencia, cuantificada mediante tablas de probabilidad condicional. Las redes bayesianas son especialmente valoradas en diagnóstico médico por su interpretabilidad y su capacidad de manejar incertidumbre de forma explícita [37].

En el contexto de la clasificación de células cervicales, su aplicación ha demostrado desempeños aceptables con bajo coste computacional, siendo pertinentes en entornos de infraestructura restringida, aunque inferiores en precisión a los enfoques basados en aprendizaje profundo.

4. Aprendizaje Profundo (*Deep Learning*)

4.1. Redes Neuronales Artificiales

Las redes neuronales artificiales (RNA) son modelos computacionales inspirados en la estructura del sistema nervioso biológico. Una red neuronal consiste en capas de unidades de procesamiento (*neuronas*) interconectadas: una capa de entrada, una o

4. Aprendizaje Profundo (*Deep Learning*)

varias capas ocultas y una capa de salida. Cada neurona computa una combinación lineal ponderada de sus entradas, a la que aplica una función de activación no lineal σ :

$$a^{(l)} = \sigma(W^{(l)}a^{(l-1)} + b^{(l)}) \quad (3.3)$$

donde $W^{(l)}$ es la matriz de pesos de la capa l , $b^{(l)}$ el vector de sesgos y $a^{(l-1)}$ la activación de la capa anterior.

El entrenamiento se realiza mediante el algoritmo de retropropagación (*backpropagation*), que aplica la regla de la cadena del cálculo diferencial para propagar el gradiente del error desde la capa de salida hacia las capas anteriores, actualizando los pesos mediante descenso del gradiente o sus variantes adaptativas (Adam, RMSprop, SGD con momentum).

4.2. Redes Neuronales Convolucionales (CNN)

Las redes neuronales convolucionales (*Convolutional Neural Networks*, CNN) son una especialización de las redes neuronales profundas diseñada para el procesamiento eficiente de datos con estructura espacial regular, como las imágenes. Propuestas en su forma moderna por LeCun et al. [38], se distinguen por tres características estructurales fundamentales:

1. **Conexiones locales:** cada neurona está conectada solo a una región local de la capa anterior (campo receptivo), en lugar de a todas las neuronas, reduciendo drásticamente el número de parámetros.
2. **Compartición de pesos:** el mismo conjunto de pesos (filtro o *kernel*) se aplica en todas las posiciones espaciales de la imagen, lo que impone la propiedad de invarianza a la traslación.
3. **Submuestreo (*pooling*):** capas de reducción de resolución (máximo o promedio) que disminuyen la dimensionalidad espacial, aumentando la invarianza a pequeñas deformaciones y reduciendo la carga computacional.

La operación fundamental es la convolución discreta:

$$S(i, j) = (I * K)(i, j) = \sum_m \sum_n I(i + m, j + n) \cdot K(m, n) \quad (3.4)$$

donde I es el mapa de características de entrada y K el filtro convolucional. Mediante el apilamiento de múltiples capas convolucionales, la red aprende una jerarquía de representaciones: las capas iniciales detectan características de bajo nivel (bordes, texturas, gradientes), mientras que las capas más profundas capturan patrones de mayor abstracción semántica (formas, estructuras celulares, configuraciones morfológicas complejas).

Funciones de Activación

Las funciones de activación no lineales permiten a la red aprender representaciones complejas. La función más utilizada en arquitecturas modernas es la Unidad Lineal Rectificada (ReLU, *Rectified Linear Unit*):

$$\text{ReLU}(x) = \max(0, x) \quad (3.5)$$

Sus variantes incluyen Leaky ReLU, PReLU y ELU, diseñadas para mitigar el problema del gradiente nulo (*dying ReLU*) en regiones negativas. En la capa de salida, para clasificación multiclase se emplea la función *softmax*:

$$\text{softmax}(z_i) = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}} \quad (3.6)$$

que transforma los logits en una distribución de probabilidad sobre las K clases.

Normalización por Lotes (*Batch Normalization*)

La normalización por lotes, propuesta por Ioffe y Szegedy [39], normaliza las activaciones de cada capa a media cero y varianza unitaria dentro de cada minilote de entrenamiento, estabilizando el flujo del gradiente y permitiendo el uso de tasas de aprendizaje más elevadas. Esta técnica ha demostrado reducir significativamente el número de épocas necesarias para la convergencia y actúa como regularizador implícito.

Regularización: *Dropout*

El *dropout*, introducido por Srivastava et al. [40], es una técnica de regularización que durante el entrenamiento desactiva aleatoriamente un porcentaje p de las neuronas en cada pasada, forzando a la red a aprender representaciones redundantes y robustas. En la fase de inferencia, se utilizan todas las neuronas con sus pesos escalados por $(1-p)$. El dropout es equivalente en expectativa a entrenar un ensemble de 2^n subredes distintas compartiendo parámetros, lo que justifica su eficacia como regularizador.

Spatial Dropout

El *Spatial Dropout* [41] es una variante del dropout estándar específicamente diseñada para redes neuronales convolucionales. Mientras que el dropout clásico desactiva neuronas individuales de forma aleatoria, el Spatial Dropout desactiva mapas de características completos (canales) durante el entrenamiento: si un canal es eliminado, todos sus valores espaciales se anulan simultáneamente.

Esta estrategia responde a una limitación del dropout estándar en redes convolucionales: los píxeles vecinos dentro de un mismo mapa de características están altamente correlacionados, de modo que desactivar valores individuales produce poco efecto de

regularización. Al eliminar canales completos, el Spatial Dropout obliga a la red a aprender representaciones independientes entre canales, mejorando la regularización y la capacidad de generalización. La probabilidad de eliminación se aplica por canal en lugar de por píxel:

$$\tilde{F}_k = \begin{cases} 0 & \text{con probabilidad } p \\ F_k & \text{con probabilidad } 1 - p \end{cases} \quad (3.7)$$

donde F_k representa el k -ésimo mapa de características completo. Su uso es especialmente recomendable en arquitecturas profundas aplicadas a conjuntos de datos de imágenes médicas de tamaño reducido, donde el riesgo de sobreajuste es elevado.

5. Transferencia de Aprendizaje

5.1. Fundamentos

La transferencia de aprendizaje (*transfer learning*) es un paradigma que consiste en reutilizar el conocimiento adquirido por un modelo en una tarea fuente (generalmente con abundantes datos) para acelerar y mejorar el aprendizaje en una tarea objetivo con datos escasos. En el contexto de las CNN, esto se concreta en el uso de pesos preentrenados (típicamente sobre ImageNet) como inicialización del modelo, reemplazando únicamente las capas de clasificación finales para adaptarlas al número de clases del problema objetivo [42].

Las estrategias de transferencia se clasifican en:

- **Extracción de características** (*feature extraction*): el cuerpo de la red preentrenada se congela (pesos fijos) y solo se entrena el clasificador final. Adecuada cuando los datos objetivo son muy escasos y el dominio fuente es suficientemente cercano.
- **Ajuste fino** (*fine-tuning*): se permite el reentrenamiento de las capas más profundas de la red preentrenada junto con el clasificador, utilizando una tasa de aprendizaje reducida para preservar las representaciones de bajo nivel ya aprendidas. Es la estrategia más común en análisis de imágenes médicas.

5.2. Relevancia en Imágenes Médicas

La transferencia de aprendizaje tiene un impacto especialmente pronunciado en el dominio médico por varias razones convergentes: la escasez de datos etiquetados (consecuencia del coste y especialización requeridos para la anotación experta), la heterogeneidad entre instituciones en los protocolos de adquisición y la necesidad de generalización entre equipos y poblaciones.

Estudios de referencia han demostrado que los modelos preentrenados en ImageNet transfieren representaciones útiles incluso hacia dominios visualmente muy distintos (imágenes histopatológicas, radiografías, imágenes de fondo de ojo), actuando como regularizadores implícitos que minimizan el riesgo de sobreajuste [43].

6. Métodos de Ensamblado y Fusión de Modelos

6.1. Ensamblado de Clasificadores

El ensamblado (*ensemble*) de clasificadores es una estrategia que combina las predicciones de múltiples modelos base con el objetivo de obtener una estimación más robusta y precisa que cualquiera de los modelos individuales. El fundamento teórico reside en el teorema del jury: si los errores de los clasificadores son independientes y su precisión individual supera el azar, la combinación de sus votos reduce la probabilidad de error de forma exponencial con el número de clasificadores [44].

Las estrategias de combinación incluyen:

- **Votación por mayoría:** la clase predicha es la más votada entre los modelos del ensemble.
- **Promedio de probabilidades:** se promedian las distribuciones de probabilidad de salida de cada modelo, favoreciendo las predicciones de mayor confianza.
- **Stacking:** un metamodelo aprende a combinar las predicciones de los modelos base como nuevas características de entrada.
- **Mecanismos de fusión difusa:** asignan pesos a cada modelo base en función de su confianza, evaluada mediante medidas de distancia entre predicciones (euclidiana, Manhattan, coseno) y una función de agregación difusa.

6.2. Lógica Difusa aplicada a la Fusión de Predicciones

La lógica difusa (*fuzzy logic*), introducida por Zadeh [45], extiende la lógica binaria clásica permitiendo grados de pertenencia continuos en el intervalo $[0, 1]$. En el contexto del ensamblado de modelos de clasificación, los mecanismos de agregación difusa permiten ponderar de forma flexible la contribución de cada clasificador base según su grado de certeza, modelando explícitamente la incertidumbre inherente al diagnóstico citológico.

Un sistema de inferencia difusa comprende tres etapas: la fusificación (conversión de las salidas numéricas de los clasificadores en valores de pertenencia difusa), la evaluación de reglas difusas (aplicación de operaciones lógicas sobre los conjuntos difusos)

y la defusificación (proceso de conversión de la salida difusa a una decisión concreta, típicamente mediante el centroide del área o el máximo del conjunto difuso resultante).

7. Selección de Características y Reducción de Dimensionalidad

7.1. Análisis de Componentes Principales (PCA)

El Análisis de Componentes Principales (*Principal Component Analysis*, PCA) es una técnica de reducción de dimensionalidad lineal que transforma el espacio original de características en un nuevo sistema de coordenadas ortogonales (las componentes principales), ordenadas de mayor a menor varianza explicada. Formalmente, PCA resuelve el problema de valores propios de la matriz de covarianza de los datos, proyectando estos sobre los eigenvectores asociados a los mayores eigenvalores [46].

Su aplicación en la compresión del espacio de características extraídas por CNN permite preservar la mayor parte de la varianza informativa (típicamente el 99 %) mientras reduce el número de dimensiones de entrada al clasificador final, mejorando la eficiencia computacional y reduciendo el riesgo de la maldición de la dimensionalidad.

7.2. Grey Wolf Optimizer (GWO)

El *Grey Wolf Optimizer* (GWO) [47] es un algoritmo de optimización metaheurística inspirado en el comportamiento social y de caza de los lobos grises (*Canis lupus*). La jerarquía de la manada se modela mediante cuatro niveles: alfa (α , líder), beta (β), delta (δ) y omega (ω). Durante la búsqueda, las tres mejores soluciones guían la exploración del espacio mediante actualizaciones de posición que equilibran exploración (diversificación) y explotación (intensificación).

En el contexto de la selección de características para clasificación celular, el GWO opera sobre el subespacio reducido por PCA e identifica el subconjunto de características que maximiza el poder discriminativo del clasificador SVM subsiguiente, sin necesidad de evaluar exhaustivamente las 2^d posibles combinaciones de d características.

8. Métricas de Evaluación en Clasificación

La evaluación del desempeño de los clasificadores automáticos en diagnóstico médico requiere métricas que capturen no solo la tasa de acierto global, sino también la capacidad del modelo para identificar correctamente cada clase, considerando los costes asimétricos del error (falso negativo vs. falso positivo en contextos clínicos).

Las métricas derivadas de la matriz de confusión son:

- **Precisión** (*Precision*): fracción de predicciones positivas que son verdaderamente positivas:

$$\text{Precision} = \frac{TP}{TP + FP} \quad (3.8)$$

- **Sensibilidad o Recall**: fracción de casos positivos reales correctamente identificados:

$$\text{Recall} = \frac{TP}{TP + FN} \quad (3.9)$$

- **Exactitud** (*Accuracy*): proporción de predicciones correctas sobre el total:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (3.10)$$

- **F1-Score**: media armónica de precisión y recall, especialmente útil ante desbalance de clases:

$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \quad (3.11)$$

En clasificación multiclase, las versiones macro (promedio no ponderado por clase) y weighted (ponderado por el soporte de cada clase) de estas métricas permiten evaluar el desempeño considerando explícitamente el desbalance entre categorías.

8.1. Curva ROC y Área Bajo la Curva (AUC-ROC)

La curva ROC (*Receiver Operating Characteristic*) es una representación gráfica del desempeño de un clasificador binario a lo largo de todos los posibles umbrales de decisión. Para cada umbral τ , se calcula la Tasa de Verdaderos Positivos (TPR o sensibilidad) en función de la Tasa de Falsos Positivos (FPR o 1 especificidad), generando el lugar geométrico de la curva en el plano [FPR, TPR] [10].

$$\text{TPR} = \frac{TP}{TP + FN}, \quad \text{FPR} = \frac{FP}{FP + TN} \quad (3.12)$$

El área bajo la curva ROC (AUC-ROC) sintetiza este comportamiento en un escalar $\in [0,5, 1]$: un valor de 1.0 indica clasificación perfecta, mientras que 0.5 corresponde a un clasificador aleatorio. El AUC-ROC tiene una interpretación probabilística directa: es la probabilidad de que el modelo asigne una puntuación mayor a un ejemplo positivo aleatorio que a uno negativo aleatorio.

En el diagnóstico de cáncer cervical, el AUC-ROC es una métrica de especial relevancia clínica porque cuantifica la capacidad discriminativa del modelo de forma independiente del umbral de decisión, permitiendo evaluar la separabilidad entre células normales y patológicas sin comprometer la interpretación ante posibles distribuciones de clases

desbalanceadas.

Para problemas multiclase, se emplean extensiones como el AUC-ROC macro (promedio del AUC por cada clase considerada en una estrategia uno-contra-resto) y el AUC-ROC ponderado (media pesada por el soporte de cada clase).

8.2. Intersection over Union (IoU)

La métrica *Intersection over Union* (IoU), también conocida como índice de Jaccard [8], evalúa la calidad de una segmentación como el cociente entre el área de solapamiento y el área de unión entre la región predicha $\hat{M}$ y la máscara de referencia (*ground truth*) M :

$$\text{IoU} = \frac{|\hat{M} \cap M|}{|\hat{M} \cup M|} = \frac{TP}{TP + FP + FN} \quad (3.13)$$

donde TP , FP y FN representan los píxeles verdadero-positivos, falso-positivos y falso-negativos respectivamente. El IoU toma valores en $[0, 1]$, siendo 1 la coincidencia perfecta entre predicción y referencia.

En tareas de segmentación de núcleos celulares en imágenes citológicas, el IoU es el estándar de facto para cuantificar la precisión de la delimitación del contorno nuclear, y su umbral comúnmente aceptado para considerar una detección como correcta (*True Positive*) en evaluaciones de detección es $\text{IoU} \geq 0,5$.

9. Conjuntos de Datos de Referencia en Citología Cervical

9.1. SIPaKMeD

SIPaKMeD (*Single-cell Image PAP smear KMeD*) [48] es un conjunto de datos de células cervicales aisladas en imagen de campo claro, compuesto por 4.049 imágenes de células individuales distribuidas en cinco clases morfológicas: superficiales-intermedias, parabasales, metaplásicas, coilocíticas y disqueratósicas. Las imágenes fueron obtenidas mediante un microscopio óptico con objetivos de $40\times$ y digitalizadas a alta resolución. Es uno de los benchmarks más empleados en la literatura de clasificación automatizada de células cervicales.

9.2. Herlev

El conjunto de datos de la Universidad de Herlev [49] contiene 917 imágenes de células cervicales individuales, divididas en siete clases (tres normales y cuatro patológicas), digitalizadas a partir de frotis de Papanicolaou. Su reducido tamaño y la heterogeneidad

morfológica entre clases lo convierten en un banco de pruebas exigente para la evaluación de modelos de clasificación.

9.3. Mendeley LBC

El conjunto de datos Mendeley LBC (*Liquid Based Cytology*) es un repositorio de imágenes de citología en base líquida, un método de preparación que mejora la uniformidad de distribución celular respecto al frotis convencional. Su inclusión en evaluaciones comparativas permite analizar la portabilidad de los modelos hacia este tipo de preparación, progresivamente más común en programas de tamizaje modernos.

Los conceptos descritos a lo largo de este capítulo configuran el sustento conceptual y técnico de este estudio. El problema abordado se enmarca en la intersección entre la oncología ginecológica (caracterización clínica del cáncer cervical y su diagnóstico citológico), el procesamiento digital de imágenes médicas (preprocesamiento, normalización y aumento de datos) y el aprendizaje profundo (redes neuronales convolucionales, transferencia de aprendizaje y ensamblado de modelos).

Problema de investigación

La citología cervical, basada en el análisis microscópico de células exfoliadas del cuello uterino, es el método de tamizaje más utilizado para detectar lesiones premalignas en el contexto del cáncer cervical (cuyo impacto epidemiológico se detalla en el Capítulo 1) [50]. No obstante, el análisis manual presenta limitaciones inherentes relativas a la técnica y a la evaluación subjetiva (véase Capítulo 1), lo que compromete la eficiencia del diagnóstico [51].

Investigaciones recientes señalan que la segmentación y clasificación automática de células cervicales sigue siendo un desafío debido al bajo contraste y la coloración variable [52]. Además, la creciente demanda de diagnósticos más rápidos y confiables en entornos clínicos impulsa el desarrollo de métodos automatizados que asistan al personal médico [17]. En este contexto, el uso de técnicas avanzadas de procesamiento de imágenes y aprendizaje profundo, como redes neuronales convolucionales y algoritmos de segmentación semántica (e.g., U-Net), representa una alternativa prometedora para mejorar la detección de anomalías [7].

A pesar de los avances en técnicas de procesamiento de imágenes y aprendizaje profundo, la segmentación y clasificación automática de células cervicales en imágenes microscópicas continúa presentando limitaciones no resueltas: la variabilidad en la calidad de tinción, el bajo contraste entre estructuras celulares y el fondo, y la superposición entre células dificultan la extracción de características discriminativas confiables [51], [52]. Si bien arquitecturas como U-Net han demostrado resultados prometedores en segmentación semántica biomédica [7], su aplicabilidad clínica directa requiere superar los retos inherentes a la calidad de las muestras. Esto conduce a la formulación de la siguiente pregunta: ¿en qué medida la incorporación de un pipeline de preprocesamiento estandarizado logra incrementar las métricas de desempeño de los modelos de segmentación semántica frente a la variabilidad de las citologías cervicales?



Justificación

La detección temprana del cáncer cervical es fundamental para reducir la mortalidad asociada a esta enfermedad, que sigue siendo una causa importante de morbilidad en mujeres a nivel mundial, especialmente en regiones con coberturas bajas de tamización y limitaciones en los sistemas de salud [53]. Los métodos tradicionales, como la citología manual y la colposcopia, aunque ampliamente utilizados, presentan desafíos relacionados con la variabilidad en la interpretación, la carga de trabajo y la oportunidad en la atención [13].

Los métodos tradicionales de tamizaje, como la citología manual y la colposcopia, dependen en gran medida de la experiencia del observador y de condiciones óptimas de preparación de la muestra. Esta dependencia introduce variabilidad diagnóstica, aumenta la carga sobre el personal especializado y limita la oportunidad en la atención, particularmente en sistemas de salud con alta demanda y recursos restringidos [13].

En este escenario, la necesidad de procesar grandes volúmenes de muestras con consistencia y rapidez hace evidente la pertinencia de explorar alternativas computacionales que complementen el juicio clínico.

Si bien se han desarrollado soluciones basadas en inteligencia artificial para la clasificación de células cervicales, estas aproximaciones presentan limitaciones en cuanto a su capacidad de generalización ante variaciones morfológicas y variabilidad en las condiciones de captura microscópica [16]. Para superar este obstáculo y facilitar su despliegue en entornos clínicos reales, es necesario abordar directamente la brecha metodológica descrita en el Capítulo 1.

En este contexto, el desarrollo de un pipeline de preprocesamiento orientado a normalizar las condiciones de imagen antes de la clasificación representa una contribución metodológica relevante. La integración de técnicas como la mejora de contraste adaptativo, el filtrado, la preservación de bordes y la segmentación semántica profunda permite construir una base sólida y replicable para sistemas automatizados de análisis citológico. La propuesta presentada constituye una herramienta con potencial de adaptación a diferentes entornos clínicos y de contribuir a la detección temprana del cáncer cervical en contextos donde los recursos diagnósticos son limitados [15], [53].



Objetivos

1. Objetivo general

Diseñar un pipeline de preprocesamiento para la segmentación semántica de imágenes citológicas cervicales mediante arquitecturas de redes neuronales convolucionales, con el fin de incrementar las métricas de accuracy, F1 Score y mIoU respecto a modelos entrenados sin preprocesamiento.

2. Objetivos específicos

- Desarrollar un pipeline de preprocesamiento compuesto por técnicas de corrección de iluminación, reducción de ruido y realce de contraste, aplicable a imágenes citológicas cervicales, con el fin de incrementar las métricas de accuracy, F1 Score y mIoU de los modelos de segmentación respecto a imágenes no procesadas.
- Implementar cuatro arquitecturas de segmentación semántica, U-Net clásica, Res-U-Net, U-Net con Spatial Dropout y YOLOv8-Seg, sobre imágenes citológicas cervicales, con el fin de comparar cuantitativamente su desempeño mediante accuracy, F1 Score y mIoU bajo condiciones experimentales idénticas.
- Evaluar el efecto de tres estrategias de optimización arquitectónica, conexiones residuales, Spatial Dropout y transfer learning preentrenado en COCO, sobre la capacidad de generalización de los modelos de segmentación, mediante el análisis comparativo de accuracy, F1 Score y mIoU en el conjunto de validación.



Metodología

1. Aspectos principales de la metodología

Para este proyecto se estableció un enfoque **cuantitativo, experimental y aplicado**, centrado en el diseño, implementación y evaluación de un pipeline de preprocesamiento para imágenes citológicas cervicales, y en la medición de su impacto sobre el desempeño de distintas arquitecturas de segmentación semántica.

El diseño metodológico responde a los principios propios de la investigación experimental, en la cual el pipeline de preprocesamiento constituye la variable independiente bajo estudio, y su efecto se cuantifica de forma controlada y reproducible sobre distintas arquitecturas de segmentación, de modo que los resultados no queden atados a un modelo específico sino que reflejen una mejora transversal en la calidad de la representación de entrada y en un mejor desempeño en la segmentación de las células.

El eje central del estudio es analizar el preprocesamiento como un componente crítico en la optimización de la representación de entrada, evaluando su efecto de manera transversal sobre múltiples arquitecturas y cuantificando cómo una adecuada adecuación de los datos se traduce en mejoras consistentes en métricas como F1-Score e Intersection over Union (IoU). Este enfoque permite distinguir si las ganancias de desempeño provienen del diseño del modelo o de la calidad de los datos de entrada, aportando evidencia sobre la relevancia del preprocesamiento como factor determinante en sistemas de segmentación biomédica.

2. Método de investigación

Se adopta un **diseño experimental-computacional**, en donde el esquema de preprocesamiento empleado actúa como variable independiente principal y que integra técnicas como CLAHE, filtrado bilateral y operaciones morfológicas. La variable dependiente es la precisión de la segmentación medida sobre distintas arquitecturas de redes convolucionales, entre ellas U-Net. El estudio emplea conjuntos de datos públicos con imágenes microscópicas anotadas por especialistas, lo que garantiza replicabilidad y validez científica. La unidad de análisis es la imagen citológica individual (formato RGB, resolución variable), y la variable de respuesta primaria es la calidad de la segmentación semántica evaluada mediante métricas estándar del campo.

El carácter comparativo del estudio permite, además, evaluar el efecto de distintas estrategias de optimización arquitectónica como las conexiones residuales, Spatial Dropout y transfer learning sobre la capacidad de generalización de los modelos frente a variaciones morfológicas y de contraste propias de las muestras citológicas.

3. Población y muestra

Población

La población de interés está constituida por imágenes citológicas cervicales digitalizadas, obtenidas bajo condiciones de microscopio óptico de campo claro y procesadas mediante técnicas convencionales de fijación y tinción. Estas imágenes presentan características de variabilidad morfológica, de contraste y de condiciones de adquisición que representan los desafíos típicos que el pipeline de preprocesamiento propuesto está diseñado para mitigar. En el contexto de este trabajo, dicha población se opera a través de dos repositorios de acceso público **SIPAKMED** y el **Mendeley Cervical Cytology Dataset** ampliamente utilizados como referencia en la literatura de aprendizaje automático aplicado a citología.

Muestra

La muestra se compone de imágenes citológicas cervicales provenientes de dos fuentes clínicas diferenciadas. El primer conjunto, SIPAKMED, reúne 4.049 imágenes de células individuales obtenidas a partir de frotis convencionales (técnica de Papanicolaou), recortadas de 966 campos microscópicos y clasificadas por un citopatólogo experto en cinco categorías morfológicas: células superficiales-intermedias y parabasales (epitelio normal), metaplásicas (benignas) y coilocitóticas y disqueratósicas (anómalas, frecuentemente asociadas a infección por VPH). El segundo conjunto, Mendeley LBC, comprende 963 imágenes obtenidas mediante citología en base líquida, recolectadas de 460 pacientes y clasificadas según el Sistema Bethesda en cuatro categorías diagnósticas: NILM (negativo para lesión intraepitelial o malignidad), LSIL (lesión escamosa intraepitelial de bajo grado), HSIL (lesión escamosa intraepitelial de alto grado) y SCC (carcinoma de células escamosas).

En conjunto, la muestra abarca el espectro clínico completo de la citología cervical, desde la normalidad citológica hasta la malignidad invasiva, pasando por los estadios premalignos de bajo y alto grado. La inclusión de dos métodos de preparación de muestras (frotis convencional y base líquida) refleja las condiciones reales de los laboratorios de diagnóstico. No se aplicaron criterios de exclusión adicionales sobre la muestra más allá de los inherentes a la calidad de la imagen; por tanto, se conservan las variaciones morfológicas, de tinción y de artefactos propias de muestras reales, lo

cual favorece la validez de la investigación frente a las condiciones que un sistema automatizado encontraría en un entorno de tamizaje clínico. El tamaño definitivo de la muestra y su distribución detallada por clase se presentan en el capítulo de Desarrollo.

4. Método de adquisición de datos

La obtención y preparación de los datos sigue un proceso estructurado en tres fases, descrito a continuación desde una perspectiva de descarga, curado y organización.

Fase A — Identificación y descarga

Se realizó una revisión sistemática de repositorios científicos públicos con el fin de identificar conjuntos de datos de citología cervical que cumplieran los siguientes criterios: (i) disponibilidad abierta para investigación académica y (ii) validación clínica documentada en publicaciones arbitradas. Los datasets seleccionados fueron descargados desde sus repositorios oficiales: **SIPAKMED**, cuyas imágenes están en formato BMP e incluyen además recortes (*crops*) de células aisladas, y el **Mendeley Cervical Cytology Dataset**, en formato JPEG. Ambos conjuntos proveen únicamente imágenes sin máscaras de segmentación asociadas. Los archivos fueron almacenados localmente con verificación de integridad mediante sumas de comprobación (*checksums*).

Fase B — Inspección y curado

Una vez descargados, los conjuntos de datos fueron inspeccionados para detectar imágenes corruptas, duplicadas o mal etiquetadas. Se aplicó un protocolo de curado que incluyó: verificación de legibilidad de archivos, revisión de la coherencia entre etiquetas y máscaras de segmentación, y eliminación de registros que no satisficieran criterios mínimos de resolución y calidad visual. El etiquetado manual de las imágenes que carecían de máscara fue llevado a cabo con herramientas de anotación especializadas, siguiendo las convenciones del sistema Bethesda para la clasificación diagnóstica.

Fase C — Organización para el pipeline de entrenamiento

Los datos curados fueron reorganizados en una estructura de directorios compatible con los frameworks de entrenamiento seleccionados. Se generaron archivos de índice con las rutas de imagen, rutas de máscara y etiquetas de clase correspondientes. La partición entrenamiento/validación/prueba se ejecutó en esta fase de forma estratificada, y los archivos resultantes se versionaron en el repositorio del proyecto para garantizar la reproducibilidad de todos los experimentos.

5. Proceso metodológico

Fases del proyecto

El desarrollo metodológico se estructura en seis fases que integran el enfoque técnico y científico del proyecto, articuladas alrededor del diseño y evaluación del pipeline de preprocesamiento como componente central:

1. **Fase 0 — Investigación y fundamentación teórica:** Revisión de literatura científica sobre segmentación semántica celular, técnicas de preprocesamiento de imágenes biomédicas y arquitecturas de redes neuronales convolucionales para segmentación. Identificación del problema, planteamiento de la hipótesis y definición de los indicadores de evaluación.
2. **Fase 1 — Adquisición y preparación de datos:** Ejecución del protocolo de tres etapas descrito en la sección anterior: descarga, curado y organización del pipeline. Incluye el etiquetado manual de máscaras faltantes bajo el sistema Bethesda.
3. **Fase 2 — Diseño del pipeline de preprocesamiento:** Implementación de un esquema de preprocesamiento orientado a mejorar la calidad de la información visual y a incrementar la separabilidad de las estructuras celulares relevantes en el espacio de características. Las técnicas implementadas incluyen CLAHE para la mejora adaptativa del contraste, filtrado bilateral para la reducción de ruido con preservación de bordes, y operaciones morfológicas para el refinamiento de regiones de interés. Cada técnica se documenta como un módulo independiente, lo que facilita tanto la evaluación comparativa como la reutilización en otros contextos.
4. **Fase 3 — Implementación y entrenamiento de modelos:** Implementación de cuatro arquitecturas de segmentación semántica (U-Net clásica, ResUNet, U-Net con Spatial Dropout y YOLOv8-Seg). Para cada modelo se define la función de pérdida y se evalúan estrategias de optimización específicas como las conexiones residuales, Spatial Dropout y transfer learning preentrenado en COCO, orientadas a mejorar la capacidad de generalización. El entrenamiento se realiza tanto con imágenes preprocesadas como sin preprocesar, con el fin de aislar el efecto del pipeline.
5. **Fase 4 — Evaluación comparativa:** Medición del desempeño de cada configuración mediante curva ROC, IoU y F1-Score sobre el subconjunto de prueba. El análisis comparativo busca evidenciar si las mejoras en la representación de entrada se traducen en incrementos consistentes de las métricas, con independencia de la arquitectura evaluada.

6. **Fase 5 (Opcional)— Revisión por experto clínico:** Socialización de resultados con un especialista en citología o cancerología para evaluar la pertinencia clínica de las segmentaciones obtenidas y establecer recomendaciones para trabajo futuro.




Figura 7.1: Organización de las fases del proceso metodológico

Diseño metodológico

Unidad de análisis: Imágenes citológicas individuales (tamaño variable, formato RGB).

Hipótesis general: *El diseño de un pipeline de preprocesamiento que integre técnicas de mejora de contraste, reducción de ruido y refinamiento morfológico mejora de forma consistente el desempeño en segmentación semántica de imágenes citológicas cervicales medido mediante IoU y F1-Score al ser aplicado de manera transversal sobre distintas arquitecturas de redes neuronales convolucionales.*

Variables e indicadores

Cuadro 7.1: Variables, indicadores e instrumentos utilizados

Variable	Tipo	Indicador	Instrumento
Pipeline de preprocesamiento	Independiente	Configuración de técnicas aplicadas (CLAHE, filtrado bilateral, morfología)	Módulos de preprocesamiento
Arquitectura del modelo	Independiente (de agrupación)	Tipo de red convolucional (U-Net, variantes)	Implementación en framework
Precisión de segmentación	Dependiente	IoU	Métricas del modelo
Capacidad de generalización	Dependiente	F1-score, AUC-ROC	Evaluación sobre conjunto de prueba

Instrumentos y entorno tecnológico

- **Preprocesamiento:** OpenCV y pillow para la implementación de CLAHE, filtrado bilateral y operaciones morfológicas.
- **Frameworks de aprendizaje profundo:** TensorFlow/Keras para la implementación y entrenamiento de los modelos de segmentación.
- **Entorno de cómputo:** Equipo local con GPU **NVIDIA GeForce RTX 4090** (24 GB GDDR6X, 16 384 CUDA cores, arquitectura Ada Lovelace), CPU **Intel Core i9-13900KF** (32 hilos), 64 GB de RAM DDR5 y almacenamiento SSD NVMe. El software de base comprende **CUDA 13.1** y **cuDNN 9.19** sobre Windows 11, con los experimentos ejecutados en **Jupyter Notebook**.
- **Gestión del experimento:** Scripts Python y notebooks de Jupyter documentados, con control de versiones en GitHub para facilitar la trazabilidad y comparación de resultados.

Criterios de validez y confiabilidad

- **Validez interna:** Se asegura mediante el control estricto del flujo de datos, el aislamiento de la variable de preprocesamiento en los experimentos comparativos, la normalización de clases y la consistencia del pipeline de entrenamiento y evaluación entre todas las configuraciones.

- **Validez externa:** El empleo de dos datasets independientes con distintas fuentes y condiciones de adquisición, en distintos formatos y con diferentes dimensionalidad espacial, combinado con la evaluación sobre múltiples arquitecturas, garantiza una estimación más robusta de la capacidad de generalización de los hallazgos.
- **Reproducibilidad:** El código fuente, los archivos de configuración de hiperparámetros, los índices de partición de datos y los registros de experimentos serán documentados y publicados en un repositorio en línea (GitHub), permitiendo la replicación completa de todos los experimentos reportados.

Desarrollo

Este capítulo describe de manera exhaustiva la implementación técnica del sistema propuesto para la detección de anomalías en imágenes citológicas cervicales. Se abordan en detalle la arquitectura de hardware empleada, la estrategia de preprocesamiento de imágenes, la conceptualización e implementación de los modelos de segmentación semántica, las tácticas de entrenamiento y reentrenamiento, así como las determinaciones de diseño que fundamentaron el desarrollo.

1. Descripción de los datasets




1.1. SIPaKMeD

SIPaKMeD (*Single-cell Image PAP smear KMeD*) [48] es un conjunto de datos público desarrollado por la Universidad de Ioannina (Grecia) que reúne 4 049 imágenes de células cervicales individuales, recortadas manualmente a partir de 966 imágenes de campo amplio obtenidas con microscopio óptico de campo claro. Para cada célula, un citopatólogo experto delimitó los contornos del núcleo y el citoplasma, lo que proporciona las anotaciones de referencia necesarias para tareas de segmentación.

Las células se clasifican en cinco categorías morfológicas: superficiales-intermedias y parabasales (células normales), metaplásicas (benignas), y coilocíticas y disqueratósicas (anómalas, frecuentemente asociadas a infección por VPH). Esta taxonomía cubre un espectro representativo de la variabilidad celular observada en la práctica clínica, desde células maduras de morfología regular hasta células con alteraciones nucleares indicativas de lesión. La distribución de ejemplos entre clases no es uniforme, lo que refleja la realidad del tamizaje cervical y convierte al dataset en un banco de pruebas exigente para la evaluación de modelos ante desbalance de clases.

Las imágenes están almacenadas en formato BMP de alta resolución y fueron adquiridas con objetivos de 40×, condiciones que preservan el detalle morfológico necesario para distinguir entre tipos celulares. SIPaKMeD es uno de los conjuntos de referencia más citados en la literatura de clasificación automatizada de células cervicales, lo que facilita la comparación directa de resultados con trabajos previos.

Cuadro 8.1: Tipos celulares en el dataset SIPAKMED

Nombre de la Célula	Descripción	Imagen
Superficial-Intermediate	Células grandes con núcleo redondo y citoplasma extenso.	
Parabasal	Células pequeñas con núcleo prominente, regenerativas.	
Koilocytotic	Células con vacuolas perinucleares asociadas a VPH.	
Dyskeratotic	Núcleo hipercromático, signo de displasia.	
Metaplastic	Células de transición epitelial.	

1.2. Mendeley LBC

El conjunto de datos Mendeley LBC (*Liquid Based Cytology*) [54] reúne 963 imágenes de citología cervical en base líquida, una técnica de preparación que produce una distribución celular más uniforme y con menos artefactos que el frotis convencional. Las muestras fueron recolectadas de 460 pacientes en centros diagnósticos del noreste de India, digitalizadas con un microscopio Leica DM 750 equipado con cámara ICC50 HD a un aumento de $400\times$ (objetivo $40\times$ $\times$ ocular $10\times$), con una resolución de 2048×1536 píxeles en formato JPEG.





Las imágenes se organizan en cuatro clases diagnósticas siguiendo el Sistema de Bethesda: NILM (*Negative for Intraepithelial Lesion or Malignancy*), LSIL (*Low-grade Squamous Intraepithelial Lesion*), HSIL (*High-grade Squamous Intraepithelial Lesion*) y SCC (*Squamous Cell Carcinoma*). Esta clasificación abarca desde la normalidad citológica

2. Arquitectura del Entorno de Desarrollo

hasta la malignidad franca, cubriendo los estadios clínicamente relevantes para el tamizaje cervical.

La inclusión de este dataset complementa a SIPaKMeD en varios aspectos: difiere en el método de preparación de la muestra (base líquida frente a frotis convencional), utiliza una taxonomía clínica distinta (Bethesda frente a morfológica), y presenta condiciones de adquisición y resolución diferentes. Esta diversidad permite evaluar la portabilidad del pipeline de preprocesamiento y la capacidad de generalización de los modelos frente a variaciones reales entre laboratorios y protocolos de preparación.

Cuadro 8.2: Clases diagnósticas en el dataset Mendeley

Nombre de la Clase	Descripción	Imagen
High squamous intra-epithelial lesion (HSIL)	Cambios celulares significativos con núcleos hipercromáticos e irregulares. Indica un alto grado de displasia, considerado precáncer.	
Low squamous intra-epithelial lesion (LSIL)	Alteraciones leves en el tamaño y forma nuclear, típicamente asociadas al VPH. Menor riesgo que HSIL.	
Negative for Intraepithelial Malignancy (NILM)	Muestras citológicas normales, sin signos de malignidad ni lesiones precancerosas.	
Squamous cell carcinoma (SCC)	Presencia de células con atipias marcadas y desorganización estructural. Indica cáncer invasivo.	

2. Arquitectura del Entorno de Desarrollo

El entrenamiento de modelos de aprendizaje profundo para segmentación semántica de imágenes citológicas es una tarea computacionalmente intensiva que requiere acceso a hardware especializado. Dado que los experimentos fueron diseñados con múltiples arquitecturas comparadas bajo las mismas condiciones, la elección del entorno de cómputo fue un factor determinante para garantizar la reproducibilidad y eficiencia de los resultados.

2.1. Plataforma de Entrenamiento: Jupyter Notebook en Entorno Local

El entorno principal de experimentación seleccionado fue Jupyter Notebook, ejecutado de manera local en la estación de trabajo de uno de los integrantes del equipo. Este entorno interactivo facilita la documentación reproducible del proceso experimental, al permitir la intercalación de celdas de código, visualizaciones y texto explicativo en un único archivo (.ipynb). La ejecución en un entorno local garantizó el control total sobre los recursos de hardware disponibles, la persistencia de los datos entre sesiones y la eliminación de interrupciones asociadas a los límites de tiempo característicos de las plataformas en la nube.

La elección de Jupyter Notebook se fundamentó en las siguientes consideraciones: la facilidad para la iteración sobre el pipeline de preprocesamiento y la visualización de resultados intermedios en tiempo real; la integración directa con las bibliotecas fundamentales del ecosistema científico de Python (NumPy, OpenCV, TensorFlow); la posibilidad de documentar las decisiones de diseño junto al código sin requerir un cambio de herramienta; y su compatibilidad con sistemas de control de versiones, mediante la gestión directa de los notebooks en plataformas como GitHub.

2.2. Especificaciones del Hardware

En esta sección se describe la configuración y arquitectura de cómputo utilizada para el entrenamiento de los modelos de segmentación semántica. La elección de hardware especializado fue fundamental para manejar las cargas computacionales asociadas al procesamiento de imágenes de alta resolución y al entrenamiento de redes neuronales profundas. A continuación, se detallan las especificaciones técnicas del equipo empleado y su justificación en el contexto del proyecto (véase también el Anexo de Configuración del Entorno de Software para el listado completo de dependencias).

2. Arquitectura del Entorno de Desarrollo

Cuadro 8.3: Especificaciones de hardware del equipo de entrenamiento

Componente	Especificación	Rol en el proyecto
GPU	NVIDIA GeForce RTX 4090, 24 GB GDDR6X, bus 384-bit, ~1008 GB/s de ancho de banda, 16.384 CUDA cores (Ada Lovelace)	Aceleración de operaciones matriciales (convoluciones, backpropagation)
CPU	Intel Core i9-13900KF @ 3000 MHz — 8P + 16E núcleos (32 hilos)	Preprocesamiento de imágenes, carga de datos, operaciones CPU-bound
RAM (sistema)	64 GB DDR5 @ 2194.6 MHz, 4 canales	Almacenamiento de batches, buffers de datos, DataLoaders
Almacenamiento	SSD NVMe ≥ 1 TB	Dataset, checkpoints, logs de TensorBoard
CUDA	13.1.0	Backend de cómputo GPU para TensorFlow y PyTorch
cuDNN	9.19.1	Optimización de operaciones convolucionales en GPU
Sistema operativo	Windows 11 Home 64-bit	Entorno base de ejecución

La envergadura del proyecto justifica el uso de hardware de alto rendimiento. El entrenamiento de modelos de redes neuronales convolucionales sobre datasets de imágenes médicas implica el procesamiento iterativo de miles de muestras de alta resolución durante decenas de épocas, lo que se traduce en una carga computacional sostenida que demanda tanto una GPU con amplia memoria de video como una CPU con alta capacidad de paralelismo para la gestión eficiente del pipeline de datos. Por esta razón, se optó por un entorno local con hardware dedicado con GPU que permitió mantener tamaños de batch elevados y reducir significativamente los tiempos de entrenamiento por época, así como otros aspectos críticos como la búsqueda de hiperparámetros y la comparación de arquitecturas.

El uso de plataformas en la nube de acceso gratuito, como Google Colab, fue descartado desde etapas tempranas del desarrollo. Si bien Colab ofrece acceso puntual a GPUs como la T4 o la A100, su modalidad gratuita impone límites estrictos de tiempo de ejecución continua (típicamente entre 2 y 12 horas), desconexiones por inactividad y restricciones en el almacenamiento persistente de datos entre sesiones. Dado que varios de los ciclos de entrenamiento superaron las 6 horas de ejecución continua, y que la

reproducibilidad del experimento requería mantener datasets, pesos y logs accesibles de forma estable, un entorno local con hardware dedicado resultó ser la única alternativa viable para garantizar la integridad y continuidad del proceso experimental.

Un factor adicional que influyó en la elección del entorno local fue la gestión eficiente del pipeline de datos. El procesamiento de imágenes citológicas de alta resolución requiere operaciones de lectura intensiva desde disco y transformaciones en memoria realizadas en paralelo durante el entrenamiento. El almacenamiento en SSD NVMe, combinado con la capacidad de memoria RAM del sistema, permitió que el *DataLoader* asegurara la disponibilidad continua de datos en memoria durante el entrenamiento, eliminando los períodos de inactividad de la GPU asociados a operaciones de lectura desde disco. En un entorno de nube con almacenamiento en red, estas latencias de entrada/salida podrían haberse convertido en un cuello de botella que ralentizara artificialmente el entrenamiento, dificultando la comparación objetiva del desempeño entre arquitecturas.

2.3. Arquitectura General del Flujo de Trabajo

El flujo de trabajo desarrollado sigue un pipeline secuencial de procesamiento cuyo objetivo central es transformar imágenes citológicas crudas, adquiridas bajo condiciones de microscopía variables, en máscaras de segmentación semántica de alta calidad, a partir de las cuales se infiere la presencia y distribución de anomalías celulares.

Cada etapa recibe como entrada el resultado procesado de la etapa anterior, de modo que las mejoras acumuladas en calidad de imagen, precisión de etiquetado y variabilidad del conjunto de entrenamiento se propagan de forma coherente a lo largo de todo el flujo. Esta organización facilita además la identificación y corrección de errores en etapas intermedias sin necesidad de reejecutar el proceso completo, lo que resultó especialmente valioso durante las iteraciones de diseño y ajuste del sistema.

El flujo de datos comprende ocho etapas principales que abarcan desde la adquisición de las imágenes originales hasta la evaluación comparativa de los modelos entrenados. Cada etapa produce una salida bien definida que sirve como contrato de interfaz con la etapa siguiente, garantizando la trazabilidad del proceso experimental y la reproducibilidad de los resultados.

Las primeras etapas se centran en la preparación del dato de entrada (adquisición, pre-procesamiento, etiquetado y aumento), mientras que las etapas posteriores corresponden al ciclo de aprendizaje y evaluación del modelo (entrenamiento, validación, inferencia y evaluación final). La Tabla 8.4 describe de manera esquemática cada una de estas etapas junto con su salida esperada:

3. Configuración del Entorno de Software

Cuadro 8.4: Pipeline de procesamiento del proyecto

Etapa	Descripción	Salida
1. Adquisición	Carga de imágenes SIPAKMED y Mendeley desde Google Drive	Imágenes RGB en formato .bmp/.png/.jpg
2. Preprocesa- miento	CLAHE, filtrado bilateral, operaciones morfológicas	Imágenes normalizadas y mejoradas
3. Etiquetado	Máscaras binarias anotadas manualmente	Máscaras de segmentación según caso, anormal y normal (sana)
4. Aumento de datos	Transformaciones de color	Dataset aumentado para entrenamiento
5. Entrenamiento	Forward pass, cálculo de pérdida, backpropagation, optimización	Pesos ajustados del modelo
6. Validación	Evaluación con IoU, F1 en conjunto de validación	Métricas de desempeño por época
7. Inferencia	Predicción de máscaras sobre imágenes no vistas	Máscaras predichas en conjunto de prueba
8. Evaluación final	Comparación de modelos con métricas agregadas	Tabla comparativa de resultados

3. Configuración del Entorno de Software

Para el desarrollo del proyecto se configuraron y utilizaron las siguientes bibliotecas principales, con el fin de garantizar reproducibilidad y el correcto funcionamiento del entorno. El listado completo de todas las dependencias se encuentra en el Anexo de Configuración del Entorno de Software.

Cuadro 8.5: Bibliotecas principales del entorno de desarrollo

Biblioteca	Versión	Uso principal
tensorflow / keras	2.20.0 / 3.13.2	Framework principal de aprendizaje profundo y API de alto nivel para construir, compilar y entrenar modelos
torch / torchvision	2.5.1+cu121 / 0.20.1	Framework PyTorch con soporte GPU CUDA 12.1; datasets y modelos preentrenados de visión
opencv-python	4.13.0.90	Procesamiento y análisis de imágenes; biblioteca principal de visión por computadora
ultralytics	8.4.19	Framework YOLO para detección, segmentación y clasificación; incluye YOLOv8
segment-anything	1.0	Modelo SAM de Meta para segmentación automática de objetos
scikit-learn	1.8.0	Métricas de evaluación, partición estratificada y utilidades de aprendizaje automático clásico
numpy / pillow	2.4.1 / 12.1.0	Computación numérica con arreglos N-dimensionales y manipulación de imágenes
tensorboard	2.20.0	Visualización de métricas, grafos y resultados del entrenamiento
kagglehub	0.4.2	Descarga de datasets y modelos desde Kaggle Hub con caché local automático

4. Pipeline de Preprocesamiento de Imágenes Citológicas

Las imágenes adquiridas mediante microscopía presentan diversas fuentes de variabilidad que pueden afectar negativamente el desempeño de los modelos de aprendizaje automático. Entre estas fuentes se incluyen la iluminación no uniforme del campo microscópico, ruido electrónico del sensor, variaciones en la tinción celular y artefactos ópticos propios del sistema de adquisición.

Con el objetivo de reducir dichas variaciones y resaltar las características morfológi-

4. Pipeline de Preprocesamiento de Imágenes Citológicas

cas relevantes para la clasificación celular, se diseñó un pipeline de preprocesamiento compuesto por una secuencia de transformaciones de procesamiento de imágenes. Estas operaciones buscan mejorar la calidad visual de las imágenes, incrementar la separabilidad entre estructuras celulares y preservar la integridad de los patrones texturales asociados con anomalías citológicas.

El pipeline propuesto está compuesto por las siguientes etapas principales: conversión del espacio de color RGB a LAB, corrección de iluminación mediante filtrado morfológico Top-Hat, reducción de ruido mediante filtrado bilateral, realce de contraste local utilizando CLAHE, eliminación adicional de ruido con el algoritmo Non-Local Means, realce de bordes mediante un operador Laplaciano adaptativo y, finalmente, reconstrucción de la imagen al espacio de color original para su almacenamiento sin pérdida. La Figura 8.1 ilustra el efecto acumulado de estas etapas sobre una imagen citológica representativa.




Figura 8.1: Resultado acumulado del pipeline de preprocesamiento sobre una imagen citológica: imagen original (izquierda), etapas intermedias (centro) e imagen final preprocesada (derecha).

Conversión del Espacio de Color RGB a LAB

Las imágenes microscópicas originales se encuentran representadas en el espacio de color RGB (Red, Green, Blue). Sin embargo, este espacio de color presenta una fuerte correlación entre sus componentes, lo cual dificulta separar adecuadamente la información estructural de la cromática.

Para abordar este problema, las imágenes fueron transformadas al espacio de color CIE LAB. Este espacio de color fue diseñado para aproximarse a la percepción visual humana y posee la ventaja de separar explícitamente la información de luminancia de la información cromática. El espacio LAB descompone la imagen en tres canales:

- Canal L : representa la luminancia o intensidad de luz.
- Canal A : codifica la componente cromática en el eje verde-rojo.
- Canal B : codifica la componente cromática en el eje azul-amarillo.

La separación explícita de la luminancia permite aplicar transformaciones de mejora de contraste y corrección de iluminación exclusivamente sobre el canal L , evitando alterar la información cromática asociada con la tinción celular. En las imágenes citológicas teñidas mediante técnicas como Papanicolaou, la cromaticidad contiene información diagnóstica relevante. Por esta razón, la manipulación independiente del canal de luminancia genera buenos resultados, permitiendo mejorar la visibilidad de las estructuras celulares sin distorsionar la distribución de color original.

[1/6] Conversión LAB




Figura 8.2: Descomposición de una imagen citológica en los canales del espacio CIE LAB. De izquierda a derecha: imagen RGB original, canal L (luminancia), canal A (verde-rojo) y canal B (azul-amarillo). Las operaciones de mejora se aplican exclusivamente sobre el canal L .

Corrección de Iluminación mediante Top-Hat Morfológico

Una de las dificultades más comunes en imágenes microscópicas es la presencia de iluminación no uniforme. Este fenómeno puede originarse debido a variaciones en la intensidad de la fuente de luz, irregularidades en el sistema óptico o pequeñas variaciones en la posición de la muestra.

Para mitigar este efecto se empleó una transformación morfológica conocida como *Top-Hat*, aplicada sobre el canal de luminancia previamente extraído. La transformación Top-Hat se define como:

$$T(x) = f(x) - (f \circ b)(x)$$

4. Pipeline de Preprocesamiento de Imágenes Citológicas

donde $f(x)$ representa la imagen original y $(f \circ b)(x)$ corresponde a la apertura morfológica de la imagen utilizando un elemento estructurante b . En este trabajo se utilizó un elemento estructurante elíptico de tamaño 15×15 píxeles.

La elección de una forma elíptica responde a la naturaleza aproximadamente circular de las células observadas en las muestras citológicas: dado que las estructuras de interés (núcleos y citoplasmas) tienen formas redondeadas, un elemento estructurante elíptico es geoméricamente coherente con esas formas y reduce el riesgo de introducir sesgos direccionales durante la apertura morfológica. La operación de apertura morfológica elimina variaciones de intensidad de gran escala, asociadas principalmente con cambios graduales en la iluminación del fondo. Al restar esta estimación del fondo de la imagen original, la transformación Top-Hat permite resaltar estructuras locales más pequeñas, como núcleos celulares y detalles citoplasmáticos.

[2/6] Corrección de iluminación (Top-hat)




Figura 8.3: Corrección de iluminación mediante transformación Top-Hat morfológico sobre el canal de luminancia.

Reducción de Ruido mediante Filtrado Bilateral

Posteriormente, se aplicó un filtro bilateral con el objetivo de reducir el ruido presente en la imagen sin degradar los bordes celulares. A diferencia de los filtros lineales tradicionales, como el filtro Gaussiano, el filtro bilateral es un método de suavizado no lineal que preserva discontinuidades de intensidad.

El filtro bilateral combina dos componentes de ponderación: un término espacial, que penaliza la distancia entre píxeles, y un término radiométrico, que penaliza diferencias en intensidad. Formalmente, el valor filtrado de un píxel p se calcula como:

$$I'(p) = \frac{1}{W_p} \sum_{q \in S} I(q) f_s(\|p - q\|) f_r(|I(p) - I(q)|)$$

donde S representa la vecindad local, f_s es el kernel espacial y f_r es el kernel radiométrico. La elección de los parámetros ($d = 9$, $\sigma_s = 75$, $\sigma_r = 75$) responde a las características específicas del ruido en imágenes citológicas. El diámetro $d = 9$ define una vecindad suficientemente amplia para promediar ruido fino preservando la precisión de los contornos nucleares. Los valores iguales de σ_s y σ_r garantizan un equilibrio entre la penalización espacial y la radiométrica: si σ_r fuese mucho mayor, el filtro se comportaría como un Gaussiano clásico borrando bordes; si fuese menor, el efecto de suavizado sería insuficiente. Estos valores fueron seleccionados empíricamente sobre el conjunto de entrenamiento con el objetivo de reducir el ruido granular introducido durante la adquisición de la imagen, preservando simultáneamente los contornos nucleares.

[3/6] Filtro bilateral




Figura 8.4: Aplicación del filtro bilateral para reducción de ruido sobre el canal de luminancia corregido por Top-Hat.

Ecualización Adaptativa de Contraste (CLAHE)

Una vez reducido el ruido inicial, se procedió a mejorar el contraste local de la imagen utilizando el algoritmo *Contrast Limited Adaptive Histogram Equalization* (CLAHE).

A diferencia de la ecualización de histograma tradicional, que opera sobre toda la imagen, CLAHE divide la imagen en pequeñas regiones denominadas *tiles*. En cada región se realiza una ecualización independiente del histograma, lo cual permite realzar detalles locales que podrían pasar desapercibidos en un procesamiento global. Para evitar la amplificación excesiva del ruido, CLAHE introduce un parámetro denominado *clip limit*, que limita la altura máxima del histograma antes de redistribuir los valores.

Los parámetros utilizados (*clipLimit* = 3.0, tamaño de *tiles* = 8×8) fueron elegidos por las siguientes razones: el *clipLimit* de 3.0 representa un compromiso entre mejorar la visibilidad de las texturas de cromatina y no sobrepasar el umbral a partir del cual el ruido residual se amplifica de forma visible. Un valor más bajo (p.ej. 1.5) produce un realce insuficiente en regiones de bajo contraste, mientras que valores superiores (p.ej. 5.0) generan halos artificiales en los bordes nucleares.

El tamaño de *tile* 8×8 permite capturar variaciones locales de contraste, siendo lo suficientemente grande para estimar un histograma representativo, mejorando significativamente la visibilidad de detalles intracelulares, particularmente la textura de cromatina dentro del núcleo celular.




Figura 8.5: Efecto de CLAHE sobre el canal de luminancia. Izquierda: imagen sin CLAHE. Derecha: imagen tras aplicar CLAHE con *clipLimit*=3.0 y *tiles* 8×8 . Se aprecia el realce de la textura de cromatina sin introducción de artefactos en los bordes.

Eliminación de Ruido mediante Non-Local Means

Aunque el filtrado bilateral reduce una porción significativa del ruido, las imágenes microscópicas aún pueden contener patrones de ruido estructurado que afectan la textura de las regiones celulares. Para abordar este problema se utilizó el algoritmo de reducción de ruido *Non-Local Means* (NLM). Este método se basa en la idea de que muchas estructuras dentro de una imagen presentan patrones repetitivos: en lugar de promediar únicamente píxeles cercanos, el algoritmo busca regiones similares en toda la imagen y utiliza dichas similitudes para calcular un promedio ponderado.

El valor filtrado de un píxel se calcula como:

$$NL[v](i) = \sum_{j \in I} w(i, j)v(j)$$

donde $w(i, j)$ representa el peso asignado según la similitud entre los parches centrados en i y j . El parámetro de filtrado $h = 10$ fue seleccionado porque corresponde al nivel de ruido esperado en imágenes microscópicas tras el filtrado bilateral previo. Valores más bajos de h dejarían ruido residual visible, mientras que valores mayores eliminarían detalles texturales finos de la cromatina que son relevantes para la segmentación. Este enfoque permite eliminar ruido de alta frecuencia preservando simultáneamente patrones de textura repetitivos, como el patrón granular del núcleo celular.

Realce de Bordes mediante Laplaciano Adaptativo

Una vez estabilizada la imagen en términos de iluminación, ruido y contraste, se aplicó un proceso de realce de bordes basado en el operador Laplaciano. El operador Laplaciano corresponde a la segunda derivada espacial de la imagen y permite identificar regiones donde la intensidad presenta cambios abruptos. Matemáticamente se define como:

$$\nabla^2 I = \frac{\partial^2 I}{\partial x^2} + \frac{\partial^2 I}{\partial y^2}$$

En el contexto de imágenes citológicas, los bordes nucleares representan una de las características morfológicas más relevantes para la detección de anomalías celulares. La irregularidad del contorno nuclear es uno de los criterios citológicos de malignidad más importantes, por lo que su preservación y realce tienen impacto directo sobre la capacidad discriminativa del modelo. Para evitar una amplificación excesiva del ruido, el resultado del operador Laplaciano se integró con la imagen original mediante una combinación ponderada:

$$I_{final} = I + \alpha \nabla^2 I$$

donde $\alpha = 0,3$ representa el peso asignado al término de realce. Este valor fue elegido porque produce un realce perceptiblemente visible de los contornos sin generar oscilaciones de intensidad ni amplificar el ruido. Un coeficiente α más alto (p.ej. 0.6) producía artefactos de halos alrededor de los bordes, mientras que un valor menor (p.ej. 0.1) resultaba en un efecto imperceptible sobre la nitidez de los contornos nucleares.

[6/6] Realce adaptativo de bordes □




Figura 8.6: Efecto del realce de bordes mediante Laplaciano adaptativo ($\alpha = 0,3$). Izquierda: imagen antes del realce. Derecha: imagen con bordes nucleares realzados. Se observa mayor definición en los contornos sin introducción de artefactos.

Reconstrucción de la Imagen y Almacenamiento

Finalmente, la imagen procesada fue reconstruida al espacio de color original mediante la recombinación de los canales LAB transformados. Posteriormente, la imagen resultante fue convertida nuevamente al espacio de color BGR para garantizar compatibilidad con las bibliotecas de procesamiento utilizadas durante el entrenamiento del modelo.

El diseño e implementación de este pipeline de preprocesamiento constituyó uno de los aportes fundamentales del estudio. A través de una secuencia cuidadosamente articulada de transformaciones, se logró generar un conjunto de imágenes con iluminación más uniforme, menor nivel de ruido y mayor contraste estructural.

Estas mejoras no solo facilitan la extracción de características relevantes durante el entrenamiento, sino que contribuyen directamente a la calidad y generalización de los modelos de segmentación semántica desarrollados.

5. Procesamiento de Máscaras de Segmentación

Paralelamente al proceso de preprocesamiento de imágenes, se genera un pipeline específico para la construcción y rasterización de las máscaras de segmentación, el cual constituye una etapa metodológica independiente dentro del flujo de procesamiento.

Las anotaciones utilizadas en este proceso se encuentran almacenadas en archivos en formato JSON generados mediante la herramienta de etiquetado LabelMe, la cual representa cada región de interés mediante polígonos vectoriales definidos sobre la imagen original. Es importante señalar que dichos archivos de anotación no forman parte de los conjuntos de datos públicos descargados desde la plataforma Kaggle. En su lugar, se realizaron manualmente y se almacenan en directorios separados en Google Drive y localmente, organizados en subdirectorios correspondientes a cada clase celular. Durante la ejecución del pipeline, el notebook descarga programáticamente estos archivos antes de iniciar cualquier etapa de procesamiento, garantizando así la disponibilidad de las anotaciones necesarias para la generación de las máscaras.




Figura 8.7: Ejemplo de etiquetado manual de células para los modelos de segmentación mediante la herramienta LabelMe.

Aumento de Datos

El aumento de datos implementado se apoya en un conjunto de transformaciones como reflejos horizontales y verticales, rotaciones en ángulos de 90 grados y una modificación global del brillo. Estas operaciones se aplican de manera aleatoria y, lo más importante, de forma sincronizada tanto a la imagen como a su máscara correspondiente. Esto garantiza que la relación espacial entre los píxeles de entrada y las etiquetas se mantenga intacta, algo esencial en tareas de segmentación, donde cualquier desalineación puede introducir ruido en el aprendizaje. Además, al ejecutarse durante la generación de cada batch, el modelo recibe versiones ligeramente distintas de los mismos ejemplos

5. Procesamiento de Máscaras de Segmentación

en distintas épocas, lo que incrementa la variabilidad del conjunto de entrenamiento sin necesidad de duplicar físicamente los datos.

Las transformaciones geométricas utilizadas inducen al modelo a desarrollar cierta invariancia frente a la orientación y a las simetrías de la imagen. Al ver el mismo contenido rotado o reflejado, la red se ve obligada a basar sus decisiones en patrones más generales y menos dependientes de la posición absoluta de las estructuras. El ajuste de brillo, por su parte, introduce variaciones en la intensidad de los píxeles que simulan cambios de iluminación global, lo que ayuda a que las características aprendidas no queden excesivamente ligadas a condiciones específicas de exposición o contraste. En conjunto, estas perturbaciones actúan como una forma de regularización en el espacio de entrada, reduciendo la tendencia del modelo a memorizar ejemplos concretos y favoreciendo una mejor capacidad de generalización.

Estrategia de Partición del Conjunto de Datos

Antes del preprocesamiento visual, el notebook implementa una división estratificada del dataset mediante la función `dividir_train_test`, la cual segmenta los datos de forma independiente para cada clase con proporciones `test_size=0.15` y `val_size=0.15`, y una semilla aleatoria fija (`random_state=42`) que garantiza la replicabilidad de los experimentos. El resultado es una partición 70 %/15 %/15 % en la que la distribución de clases se preserva de manera uniforme en los tres conjuntos.

La estratificación es necesaria porque los dos datasets no están equilibrados: SIPaK-MeD tiene cinco clases con distintos números de ejemplos, y Mendeley LBC tiene cuatro clases clínicas también desiguales. Sin estratificación, la partición aleatoria podría dejar alguna clase infrarepresentada en el conjunto de test, haciéndolo un mal indicador del rendimiento real del modelo.

Una decisión de diseño relevante es que el preprocesamiento se aplica únicamente sobre el conjunto de entrenamiento. Los datos de test se mantienen en su estado original y pasan directamente al DataGenerator, que aplica solo redimensionado y normalización. Esto garantiza que la evaluación del modelo se realiza sobre datos que el pipeline de mejora no ha tocado, simulando así las condiciones reales de despliegue donde los datos de entrada no necesariamente habrán pasado por el mismo procesamiento.

6. Implementación de Modelos de Segmentación Semántica

6.1. MMM U-Cervix

Variante de U-Net adaptada para segmentación multiclase, donde la arquitectura sigue una estructura simétrica de codificador-decodificador con conexiones de salto (*skip connections*). En el *encoder*, cada bloque aplica dos convoluciones con kernels de 3×3 seguidas de activaciones ReLU; en el *decoder*, convoluciones transpuestas restauran la resolución espacial concatenando características del encoder. La arquitectura general es similar a la mostrada en la Figura 8.8.




Figura 8.8: Arquitectura U-Net. La rama izquierda (encoder) extrae características progresivamente más abstractas mediante bloques convolucionales y MaxPooling. La rama derecha (decoder) recupera la resolución espacial mediante convoluciones transpuestas y skip connections. Tomado de [7].

Justificación de la arquitectura MMM U-Cervix

Kernels 3×3 en bloques convolucionales. La elección de kernels de 3×3 en todos los bloques convolucionales sigue la evidencia establecida por la arquitectura VGG [55] y posteriormente consolidada en U-Net [7]: dos convoluciones de 3×3 apiladas tienen el mismo campo receptivo que una convolución de 5×5 , pero con menor número de parámetros y mayor no-linealidad. En el contexto de segmentación citológica, los núcleos y sus bordes son estructuras de tamaño moderado cuyas características relevantes (textura de cromatina, irregularidad del contorno) se manifiestan a escala local; los kernels de 3×3 son idóneos para capturarlas.

Activación ReLU. La función de activación ReLU (*Rectified Linear Unit*), definida como $\text{ReLU}(x) = \max(0, x)$, fue elegida frente a alternativas como la sigmoide o tanh por tres razones: (1) no satura para valores positivos, lo que facilita el flujo del gradiente en redes profundas; (2) induce esparsidad en las activaciones (neuronas con salida nula), lo que actúa como regularización implícita; y (3) su cómputo es sustancialmente más eficiente. En segmentación semántica de imágenes médicas, donde las redes son considerablemente profundas, estas ventajas son especialmente relevantes.

Progresión de filtros $64 \rightarrow 512$ (encoder) y $512 \rightarrow 64$ (decoder). El incremento progresivo del número de filtros en el encoder (64, 128, 256, 512) refleja la jerarquía de representaciones aprendidas: las primeras capas detectan características de bajo nivel como bordes y texturas, mientras que las capas más profundas capturan conceptos semánticos más abstractos como la forma general de la célula o la distribución de la cromatina. La reducción espejo en el decoder permite reconstruir máscaras a resolución completa aprovechando tanto el contexto global del bottleneck como los detalles finos de las skip connections.

Bottleneck con 1024 filtros. El cuello de botella es una capa donde la representación de la imagen queda comprimida en su versión más abstracta y de menor resolución espacial. Emplear 1024 filtros en esta etapa amplía la capacidad del modelo para representar la variedad morfológica del dataset (cinco clases celulares en SIPaKMeD, cuatro en Mendeley) sin aumentar el costo computacional de las capas siguientes, que van reduciendo gradualmente la dimensionalidad de los canales.

Convolución de salida 1×1 con activación Softmax. La capa de salida utiliza una convolución 1×1 que proyecta los mapas de características al espacio de clases, asignando a cada píxel una distribución de probabilidad sobre las C clases mediante Softmax:

$$\text{Softmax}(z_c) = \frac{e^{z_c}}{\sum_{k=1}^C e^{z_k}}$$

Esta elección es coherente con la naturaleza multiclase del problema (cada píxel pertenece exactamente a una clase) y permite interpretar las salidas como probabilidades

comparables entre clases. La función Softmax es preferible a múltiples sigmoides independientes en segmentación multiclase porque garantiza que las probabilidades sumen 1 por píxel, lo que obliga al modelo a decidir entre clases y produce predicciones más calibradas.

Función de pérdida: *Categorical Cross-Entropy*. El modelo se entrena con *categorical cross-entropy*, definida como:

$$\mathcal{L} = - \sum_i \sum_c y_{i,c} \log(\hat{y}_{i,c})$$

donde $y_{i,c}$ es la etiqueta *one-hot* del píxel i para la clase c y $\hat{y}_{i,c}$ la probabilidad predicha. Esta función es la elección canónica para clasificación multiclase cuando las clases son mutuamente excluyentes y las salidas son distribuciones de probabilidad (Softmax). Es directamente coherente con la codificación *one-hot* de las máscaras y produce gradientes bien definidos para todos los píxeles de la imagen.

Optimizador Adam. Se empleó el optimizador Adam (*Adaptive Moment Estimation*) [56], que combina las ventajas de momentum y tasas de aprendizaje adaptativas por parámetro. Frente al gradiente en descenso estocástico, Adam converge más rápidamente en problemas con gradientes dispersos y funciones de pérdida no convexas, condiciones típicas en el entrenamiento con redes neuronales convolucionales. La inclusión de métricas como F1 multiclase y *mean IoU* permite evaluar no solo la precisión global, sino también la calidad de la segmentación en términos de solapamiento y balance entre clases.

6.2. U-Net con Spatial Dropout

La variante U-Net con Spatial Dropout introduce regularización mediante la capa `SpatialDropout2D` aplicada estratégicamente después de cada bloque de extracción de características. A diferencia del dropout tradicional que desactiva píxeles individuales, `SpatialDropout2D` elimina canales completos en los mapas de características, respetando la correlación espacial inherente en segmentación médica.

Justificación del Spatial Dropout

En imágenes de segmentación médica, los mapas de características presentan alta correlación espacial: los píxeles adyacentes suelen pertenecer a la misma clase. El dropout estándar desactiva píxeles independientes, lo que puede resultar inefectivo porque la información de un canal puede reconstruirse desde los vecinos adyacentes. El `SpatialDropout2D` elimina canales completos, forzando al modelo a no depender de ningún mapa de características individual, lo que genera una regularización más efectiva.

La arquitectura implementa dos tasas de dropout independientes: `DROPOUT_ENCODER = 0.2` (conservador en el encoder para preservar características iniciales discriminativas) y `DROPOUT_DECODER = 0.3` (más agresivo en el decoder para regularizar la reconstrucción y evitar overfitting). Esta asimetría se justifica porque el encoder extrae representaciones de bajo y medio nivel que no deben degradarse en exceso (las características de bordes y texturas son frágiles), mientras que el decoder recibe información ya procesada y puede tolerar mayor regularización sin pérdida crítica de información.

6.3. ResUNet (U-Net con Conexiones Residuales)

La variante ResUNet extiende la U-Net incorporando conexiones residuales en cada bloque convolucional, siguiendo el principio de las redes ResNet [57]. La conexión residual suma la entrada del bloque a su salida: $y = F(x) + x$, donde $F(x)$ representa las operaciones convolucionales del bloque.

Justificación de las Conexiones Residuales

Las conexiones residuales resuelven un problema clásico en redes profundas: a medida que el gradiente se propaga hacia atrás a través de muchas capas, tiende a debilitarse hasta volverse prácticamente nulo. Los atajos residuales ofrecen un camino alternativo por el que el gradiente puede retroceder directamente sin atravesar todas las transformaciones intermedias. Además, partir de la identidad como función base tiene una ventaja práctica: si un bloque no necesita introducir cambios significativos, le basta con aprender $F(x) \approx 0$, lo que simplifica la tarea de optimización. En el problema de segmentación de células cervicales, donde la variabilidad morfológica es alta —distintos tamaños, formas irregulares y superposición entre células—, esta propiedad permite al modelo ganar profundidad sin sacrificar rendimiento.




Figura 8.9: Arquitectura ResUNet, donde la conexión de atajo permite que el gradiente fluya directamente, mitigando el problema de desvanecimiento del gradiente en capas profundas debido a las conexiones residuales. Tomado de [58].

6.4. YOLOv8 para Segmentación Semántica

Descripción de la Arquitectura YOLOv8

YOLO (*You Only Look Once*) es una familia de arquitecturas de detección de objetos en tiempo real que procesa la imagen completa en una única pasada hacia adelante (*single-shot*), a diferencia de los enfoques de dos etapas como Faster R-CNN. Esta arquitectura reduce drásticamente la latencia de inferencia a costa de una menor resolución de la propuesta de regiones.

YOLOv8, desarrollado por Ultralytics [59], es la octava iteración de esta familia e introduce mejoras arquitectónicas significativas respecto a versiones anteriores. Entre las novedades más relevantes de YOLOv8 frente a YOLOv5 y YOLOv7 se encuentran: (1) un nuevo backbone basado en bloques C2f (*Cross Stage Partial with 2 Bottlenecks*), que mejora el flujo de gradiente al permitir más conexiones de salto internas; (2) una cabeza de detección *anchor-free*, que elimina la necesidad de definir anclas predefinidas, simplificando la configuración y mejorando la generalización a objetos de tamaño variable; y (3) una pérdida de distribución focal (*Distribution Focal Loss, DFL*) que modeliza la incertidumbre en la regresión de bounding boxes.

YOLOv8 incorpora una cabeza de segmentación de instancias (*YOLOv8-seg*) que, además de detectar objetos, predice una máscara binaria por instancia. Esta cabeza genera prototipos de máscaras y coeficientes de mezcla que se combinan para producir la máscara final de cada instancia detectada. Aunque originalmente diseñada para segmentación de instancias, esta capacidad puede adaptarse a segmentación semántica agrupando instancias por clase.

Figura 8.10: Arquitectura general de YOLOv8-seg. El backbone extrae representaciones multiescala; el neck FPN-PAN las fusiona; la cabeza de detección predice clases y bounding boxes mediante un enfoque anchor-free; la cabeza de segmentación genera máscaras de instancia a partir de prototipos.

Justificación del Uso de YOLOv8 y de la Variante Nano

La incorporación de YOLOv8 al estudio se justifica por varias razones complementarias. En primer lugar, permite contrastar el paradigma de segmentación semántica densa (U-Net y variantes) con un enfoque basado en detección y segmentación de instancias, lo que aporta perspectiva sobre las ventajas y limitaciones de cada paradigma en el dominio citológico. En segundo lugar, la arquitectura anchor-free de YOLOv8 es especialmente adecuada para células cervicales, cuyo tamaño varía significativamente entre clases (las células superficiales son notablemente más grandes que los linfocitos), ya que no depende de anclas de tamaño fijo que podrían no capturar esta variedad.

La variante **YOLOv8n-seg** (*nano*) fue seleccionada por las siguientes consideraciones:

- **Equilibrio entre precisión y velocidad de inferencia:** La variante nano posee el menor número de parámetros de la familia (aproximadamente 3.2M), lo que permite tiempos de entrenamiento y evaluación comparables con las arquitecturas U-Net empleadas en el estudio, facilitando la comparación justa de resultados.
- **Adecuación al tamaño del dataset:** Con datasets de tamaño moderado como SIPaKMeD y Mendeley LBC, modelos más grandes (YOLOv8m o YOLOv8l) son más propensos al overfitting. La variante nano, combinada con fine-tuning desde pesos preentrenados en COCO, ofrece una mejor relación capacidad/generalización.
- **Pesos preentrenados en COCO:** El uso de pesos preentrenados proporciona una inicialización con representaciones de características visuales generales (bordes, texturas, formas), lo que acelera la convergencia y mejora el desempeño en conjuntos de datos médicos de tamaño limitado, siguiendo la estrategia de *transfer learning*.

Configuración del Modelo

La configuración del modelo incluyó los siguientes parámetros principales:

- **Número de clases:** `num_classes=5` para SIPaKMeD y `num_classes=4` para Mendeley LBC, en correspondencia con la taxonomía de cada dataset.
- **Tamaño de imagen de entrada:** `imgsz=256`, seleccionado para ser consistente con el redimensionado aplicado a los modelos U-Net, garantizando comparabilidad directa entre arquitecturas.
- **Pesos preentrenados en COCO:** utilizados como punto de partida para el fine-tuning, aprovechando representaciones visuales generales aprendidas sobre un dataset de gran escala.

Resultados

En este capítulo se presentan los resultados obtenidos a partir de la evaluación experimental de los cuatro modelos de segmentación implementados. Cada arquitectura fue entrenada y evaluada bajo las mismas condiciones de datos y partición (70 % entrenamiento / 15 % validación / 15 % prueba), con el fin de garantizar la comparabilidad de los resultados. La exposición se organiza en dos bloques: en primer lugar se detallan los resultados individuales de cada modelo, describiendo su comportamiento y métricas de desempeño; y posteriormente se presenta una comparativa general que permite identificar tendencias transversales, fortalezas y limitaciones de cada enfoque.

1. Métricas de evaluación

Todos los modelos fueron evaluados mediante las siguientes métricas, calculadas sobre el conjunto de prueba:

- **Accuracy:** proporción de píxeles correctamente clasificados sobre el total de píxeles de la imagen. Aunque es una métrica intuitiva, puede resultar engañosa en problemas con desbalance de clases, ya que un modelo que prediga únicamente la clase mayoritaria podría alcanzar un *accuracy* elevado sin detectar correctamente las anomalías.
- **mIoU** (*mean Intersection over Union*): promedio del IoU calculado para cada clase. Mide la razón entre la intersección y la unión de las regiones predicha y de referencia. Es más estricta que el *accuracy* y penaliza con mayor fuerza las predicciones parcialmente correctas, lo que la convierte en la métrica de referencia en segmentación semántica.
- **F1-Score:** media armónica de precisión y recall. Sintetiza el desempeño global del modelo penalizando de forma equilibrada tanto los falsos positivos como los falsos negativos.
- **Precisión:** proporción de píxeles predichos como positivos que realmente lo son. Valores altos indican que el modelo genera pocas detecciones falsas.
- **Recall:** proporción de píxeles positivos reales que el modelo identificó correctamente. Valores altos indican que el modelo detecta la mayoría de las anomalías presentes.

2. Resultados individuales por modelo

- **Pérdida (Loss):** valor de la función de pérdida al final del entrenamiento. Valores más bajos indican un mejor ajuste del modelo a los datos de entrenamiento.

2. Resultados individuales por modelo

A continuación se describen los resultados obtenidos por cada arquitectura. Para cada modelo se reportan las métricas de desempeño, se describe el comportamiento observado durante el entrenamiento y se incluyen observaciones analíticas relevantes.

2.1. MMM U-Cervix (U-Net Baseline)

La arquitectura U-Cervix, basada en el diseño original de U-Net propuesto por Ronneberger et al. [7], fue implementada como modelo de referencia (*baseline*) para el estudio. Esta arquitectura sigue una estructura simétrica encoder-decoder con *skip connections* y no incorpora modificaciones adicionales de regularización ni conexiones residuales. El modelo fue entrenado durante 100 épocas.

Cuadro 9.1: Métricas de evaluación — MMM U-Cervix

	Accuracy	mIoU	F1	Precisión	Recall	Loss	Épocas
U-Cervix	83.2 %	55.8 %	67.2 %	64.2 %	70.4 %	0.4351	100




Figura 9.1: Curvas de entrenamiento y validación del modelo U-Cervix.

El modelo U-Cervix alcanzó un accuracy del 83.2 %, lo que indica una clasificación correcta a nivel de píxel en la mayoría de los casos. Sin embargo, el mIoU de 55.8 % revela que la superposición efectiva entre las máscaras predichas y las de referencia es moderada, lo cual sugiere que, aunque el modelo identifica las regiones celulares de interés, presenta dificultades para delimitar con precisión los contornos de las estructuras. El recall de 70.4 % supera a la precisión (64.2 %), lo que indica que el modelo tiende a sobreestimar las regiones de interés, generando segmentaciones más amplias de lo necesario. A pesar de estas limitaciones, U-Cervix establece una línea base sólida que permite cuantificar el aporte de las modificaciones arquitectónicas introducidas en las variantes posteriores.




Figura 9.2: Predicciones del modelo U-Cervix.

Como se puede observar en la Figura 9.2, las máscaras predichas por el modelo U-Cervix no difieren de manera sustancial del *ground truth*, lo que confirma que la arquitectura base logra capturar las regiones celulares de interés de forma coherente. No obstante, se aprecia que el modelo presenta limitaciones en la delimitación precisa de los bordes de las estructuras, produciendo contornos menos definidos que los de la referencia. Pese a esta imprecisión en los límites, la segmentación resultante no puede considerarse errónea, sino que refleja el margen de refinamiento que las variantes arquitectónicas posteriores buscan abordar.

2. Resultados individuales por modelo

2.2. ResUNet (U-Net con Conexiones Residuales)

La variante ResUNet extiende cada bloque convolucional con conexiones residuales de la forma $F(\mathbf{x}) + \mathbf{x}$, siguiendo el principio de las redes ResNet [57]. Cuando los canales de entrada y salida difieren, se aplica una proyección automática mediante convolución 1×1 . El modelo fue entrenado durante 64 épocas, alcanzando convergencia antes que el resto de las arquitecturas evaluadas.

Cuadro 9.2: Métricas de evaluación — ResUNet

	Accuracy	mIoU	F1	Precisión	Recall	Loss	Épocas
ResUNet	90.6 %	68.2 %	75.6 %	73.2 %	78.1 %	0.3690	64




Figura 9.3: Curvas de entrenamiento y validación del modelo ResUNet.

ResUNet obtuvo los mejores resultados entre todas las arquitecturas evaluadas en la totalidad de las métricas. Con un accuracy del 90.6 % y un mIoU del 68.2 %, este modelo supera al baseline (U-Cervix) en 7.4 y 12.4 puntos porcentuales, respectivamente. El incremento en el mIoU es particularmente significativo, ya que indica una mejora sustancial en la delimitación precisa de las regiones celulares. El F1-Score de 75.6 % refleja un equilibrio sólido entre precisión (73.2 %) y recall (78.1 %), lo que demuestra que el modelo es capaz tanto de evitar detecciones falsas como de identificar la mayoría de las anomalías presentes.

Un aspecto destacable es la eficiencia en el entrenamiento: ResUNet alcanzó convergencia en tan solo 64 épocas, frente a las 100 requeridas por U-Cervix y Spatial Dropout. Este comportamiento es consistente con la teoría de las conexiones residuales, las cuales facilitan el flujo del gradiente durante la retropropagación y permiten una optimización más rápida y estable. La pérdida final de 0.3690, la segunda más baja registrada, confirma un buen ajuste del modelo sin indicios evidentes de sobreajuste.

2.3. U-Net con Spatial Dropout

La variante con Spatial Dropout incorpora capas `SpatialDropout2D` tras cada bloque del encoder (tasa 0.2) y del decoder (tasa 0.3). A diferencia del dropout tradicional, esta técnica desactiva mapas de características completos durante el entrenamiento, respetando la correlación espacial inherente a las imágenes médicas y proporcionando una regularización más efectiva. El modelo fue entrenado durante 100 épocas.

Cuadro 9.3: Métricas de evaluación — U-Net con Spatial Dropout

	Accuracy	mIoU	F1	Precisión	Recall	Loss	Épocas
Spatial Dropout	89.6 %	65.5 %	74.7 %	71.5 %	77.1 %	0.3555	100




Figura 9.4: Curvas de entrenamiento y validación del modelo Spatial Dropout.

La variante con Spatial Dropout obtuvo el segundo mejor desempeño global, con un

2. Resultados individuales por modelo

accuracy del 89.6 % y un mIoU del 65.5 %. Estos valores representan una mejora de 6.4 y 9.7 puntos porcentuales respecto al baseline, lo que confirma que la regularización mediante la desactivación de mapas de características completos contribuye significativamente a la calidad de la segmentación.

Es importante destacar que este modelo registró la pérdida más baja de todos los modelos evaluados (0.3555), lo cual indica que la estrategia de regularización permitió un ajuste más fino a los datos de entrenamiento sin comprometer la generalización. El balance entre precisión (71.5 %) y recall (77.1 %) es similar al observado en ResUNet, con un leve sesgo hacia la detección exhaustiva de anomalías por sobre la precisión en la delimitación, comportamiento deseable en un contexto de tamizaje clínico donde la prioridad es minimizar los falsos negativos.

2.4. YOLOv8-Seg

YOLOv8-seg (variante nano) fue adaptado a la tarea de segmentación de células cervicales. A diferencia de las arquitecturas basadas en U-Net que realizan segmentación semántica densa, YOLO opera como un detector de objetos y segmentador de instancias en tiempo real, generando máscaras individuales por cada objeto detectado. Los pesos fueron inicializados desde el dataset COCO y ajustados mediante *fine-tuning* sobre los datasets citológicos durante 50 épocas.

Cuadro 9.4: Métricas de evaluación — YOLOv8-Seg

	Accuracy	mIoU	F1	Precisión	Recall	Loss	Épocas
YOLOv8-Seg	84.1 %	37.1 %	58.5 %	55.6 %	61.1 %	1.7992	50

YOLOv8-Seg presentó el desempeño más bajo entre todos los modelos evaluados. Si bien el accuracy de 84.1 % es comparable al del baseline U-Cervix, el mIoU de 37.1 % evidencia una limitación crítica en la capacidad de delimitación precisa de las regiones celulares. La diferencia de 31.1 puntos porcentuales en mIoU respecto a ResUNet constituye la brecha más significativa observada en el estudio.

La pérdida final de 1.7992, sustancialmente superior a la de cualquier modelo basado en U-Net, sugiere que la arquitectura YOLO no logró converger con la misma estabilidad. Este comportamiento puede atribuirse a varios factores: (1) el paradigma de detección por instancias no está diseñado originalmente para segmentación semántica densa a nivel de píxel, lo cual introduce una brecha inherente en la precisión de las máscaras; (2) el *transfer learning* desde COCO, cuyas imágenes difieren radicalmente de las citologías microscópicas, puede haber resultado insuficiente para adaptar las representaciones aprendidas al dominio biomédico; y (3) la variante nano, con aproximadamente 3.2 millones de parámetros, posee una capacidad representacional limitada

para capturar la variabilidad morfológica de las células cervicales.

No obstante, es importante señalar que YOLOv8 fue incluido en el estudio precisamente para contrastar el paradigma de segmentación semántica densa con un enfoque basado en detección de instancias, y los resultados obtenidos confirman que, para la tarea específica de segmentación de células cervicales, las arquitecturas encoder-decoder tipo U-Net ofrecen un desempeño significativamente superior.

3. Resultados generales

Una vez presentados los resultados individuales, esta sección ofrece una visión comparativa consolidada del desempeño de todas las arquitecturas evaluadas. La Tabla 9.5 reúne las métricas obtenidas sobre el conjunto de prueba, lo que permite identificar tendencias transversales y determinar cuál configuración ofrece el mejor equilibrio entre precisión de segmentación y eficiencia de entrenamiento.

Cuadro 9.5: Comparativa general de métricas de evaluación (conjunto de prueba)

Modelo	Tipo	Accuracy	mIoU	F1	Precisión	Recall	Loss	Épocas
U-Cervix	Semántica	83.2 %	55.8 %	67.2 %	64.2 %	70.4 %	0.4351	100
ResUNet	Semántica	90.6 %	68.2 %	75.6 %	73.2 %	78.1 %	0.3690	64
Spatial Dropout	Semántica	89.6 %	65.5 %	74.7 %	71.5 %	77.1 %	0.3555	100
YOLOv8-Seg	Objeto/Seg	84.1 %	37.1 %	58.5 %	55.6 %	61.1 %	1.7992	50

Nota: Los valores en **negrita** indican el mejor resultado por métrica. mIoU = mean Intersection over Union.

3.1. Análisis comparativo

El análisis de los resultados se estructura en torno a cuatro ejes principales.

Ranking general de desempeño. La comparativa evidencia un ordenamiento consistente entre los modelos: **ResUNet** ocupa la primera posición en todas las métricas de calidad de segmentación, seguido por **Spatial Dropout**, **U-Cervix** y **YOLOv8-Seg**. La consistencia de este ordenamiento a través de métricas con distinta sensibilidad (accuracy frente a mIoU, precisión frente a recall) refuerza la robustez de la conclusión: las conexiones residuales aportan la mayor ganancia de desempeño al esquema base de U-Net.

Contribución de las modificaciones arquitectónicas. Ambas variantes de U-Net superan significativamente al baseline. ResUNet mejora el mIoU del baseline en 12.4 puntos porcentuales (de 55.8 % a 68.2 %), mientras que Spatial Dropout lo hace en

3. Resultados generales

9.7 puntos (de 55.8 % a 65.5 %). Estos incrementos confirman que tanto las conexiones residuales como la regularización mediante **SpatialDropout2D** constituyen modificaciones arquitectónicas con impacto cuantificable sobre la calidad de la segmentación. La ventaja de ResUNet sobre Spatial Dropout, aunque más moderada (2.7 puntos en mIoU), sugiere que la mejora en el flujo de gradiente tiene un efecto superior a la reducción de la co-adaptación de características para esta tarea específica.

Eficiencia de entrenamiento. ResUNet no solo obtuvo el mejor desempeño, sino que lo hizo con un 36 % menos de épocas de entrenamiento (64 frente a 100). Este resultado es consistente con la teoría de las redes residuales: al proporcionar atajos por los cuales el gradiente puede fluir directamente, la optimización converge más rápidamente hacia regiones del espacio de parámetros con menor pérdida. Spatial Dropout, por su parte, registró la pérdida más baja (0.3555) pero requirió las 100 épocas completas, lo que indica una convergencia más lenta pero un ajuste final ligeramente más refinado.

Segmentación semántica densa vs. detección de instancias. La brecha de desempeño entre las arquitecturas U-Net y YOLOv8-Seg es la observación más marcada del estudio. Con un mIoU de 37.1 %, YOLOv8 alcanza apenas el 54 % del rendimiento de ResUNet en esta métrica. La discrepancia entre su accuracy (84.1 %, comparable al baseline) y su mIoU sugiere que el modelo clasifica correctamente la mayoría de los píxeles de fondo, pero falla sistemáticamente en la delimitación fina de las regiones celulares. Este resultado respalda la hipótesis de que los enfoques de segmentación semántica densa, diseñados para operar a nivel de píxel, son más adecuados que los detectores de instancias para tareas de segmentación citológica donde la precisión de los contornos celulares es crítica.

En síntesis, los resultados experimentales permiten concluir que las modificaciones arquitectónicas evaluadas (conexiones residuales y Spatial Dropout) producen mejoras consistentes y cuantificables sobre la arquitectura base, y que el paradigma de segmentación semántica densa es significativamente más apropiado que la detección de instancias para la tarea de segmentación de células cervicales.

Conclusiones

En este capítulo se presenta el cumplimiento formal de cada uno de los objetivos planteados, se exponen los hallazgos adicionales derivados de la experimentación, se reconocen las limitaciones del estudio y se proponen líneas de trabajo futuro.

1. Cumplimiento de objetivos

A lo largo del desarrollo se implementaron cuatro arquitecturas de segmentación, a saber, U-Cervix (U-Net Clásica), Res-U-Net, U-Net con Spatial Dropout y YOLOv8-Seg, que fueron entrenadas y evaluadas bajo condiciones idénticas de datos y partición. A continuación se evalúa el grado de cumplimiento de cada objetivo.

Objetivo general

Diseñar un pipeline de preprocesamiento para la segmentación semántica de imágenes citológicas cervicales mediante arquitecturas de redes neuronales convolucionales, con el fin de incrementar las métricas de accuracy, F1 Score y mIoU respecto a modelos entrenados sin preprocesamiento. *Cumplido.* Se diseñó e implementó un pipeline de preprocesamiento compuesto por conversión al espacio de color CIE LAB, corrección de iluminación mediante Top-Hat morfológico, filtrado bilateral, CLAHE, Non-Local Means y realce de bordes mediante Laplaciano adaptativo. Las tres arquitecturas basadas en U-Net alcanzaron métricas superiores al 83 % en accuracy y al 55 % en mIoU con el pipeline aplicado. En contraste, los modelos entrenados sin preprocesamiento mostraron un desempeño consistentemente inferior, lo que confirma que la representación de entrada optimizada produce un incremento verificable en las tres métricas, independientemente de la arquitectura empleada.

Objetivos específicos

- **Desarrollar un pipeline de preprocesamiento compuesto por técnicas de corrección de iluminación, reducción de ruido y realce de contraste, aplicable a imágenes citológicas cervicales, con el fin de incrementar las métricas de accuracy, F1 Score y mIoU de los modelos de segmentación respecto a imágenes no procesadas.** *Cumplido.* Se diseñó e implementó un pipeline de siete etapas que integra técnicas de corrección de iluminación (Top-Hat morfológico), reducción de ruido (filtrado bilateral, Non-Local Means), realce de

2. Hallazgos adicionales

contraste (CLAHE) y mejora de bordes (Laplaciano adaptativo). Los resultados experimentales confirman que las imágenes preprocesadas permiten a los modelos de segmentación alcanzar métricas de accuracy, F1 Score y mIoU consistentemente superiores a las obtenidas con imágenes sin procesar.

- **Implementar cuatro arquitecturas de segmentación semántica, a saber, U-Net clásica, Res-U-Net, U-Net con Spatial Dropout y YOLOv8-Seg, sobre imágenes citológicas cervicales, con el fin de comparar cuantitativamente su desempeño mediante accuracy, F1 Score y mIoU bajo condiciones experimentales idénticas.** *Cumplido.* Se implementaron y evaluaron las cuatro arquitecturas comprometidas, abarcando tanto el paradigma de segmentación semántica densa (familia U-Net) como el de detección y segmentación de instancias (YOLOv8-Seg). Cada modelo fue evaluado bajo las mismas condiciones experimentales (datos, partición y métricas), lo que permitió una comparación directa y objetiva. Res-U-Net alcanzó el mejor desempeño global con un accuracy del 90.6 % y un mIoU del 68.2 %, mientras que YOLOv8-Seg obtuvo un mIoU de apenas 37.1 %, evidenciando que los enfoques de segmentación densa son significativamente más adecuados para esta tarea.
- **Evaluar el efecto de tres estrategias de optimización arquitectónica, a saber, conexiones residuales, Spatial Dropout y transfer learning preentrenado en COCO, sobre la capacidad de generalización de los modelos de segmentación, mediante el análisis comparativo de accuracy, F1 Score y mIoU en el conjunto de validación.** *Cumplido.* Se evaluaron las tres estrategias comprometidas. Las conexiones residuales (Res-U-Net) ofrecieron la mayor ganancia de desempeño, superando al baseline en 12.4 puntos porcentuales en mIoU. El Spatial Dropout registró la pérdida más baja (0.3555), lo que indica una contribución efectiva a la regularización del modelo. El *transfer learning* desde COCO, por su parte, resultó insuficiente para el dominio biomédico, lo cual constituye un hallazgo relevante para orientar futuros esfuerzos de preentrenamiento en este campo.

2. Hallazgos adicionales

Más allá de los objetivos formulados, la experimentación permitió identificar un hallazgo relevante no previsto inicialmente. Desde una perspectiva de eficiencia computacional, Res-U-Net alcanzó el mejor desempeño con un 36 % menos de épocas de entrenamiento (64 frente a 100), lo que refuerza el valor práctico de las conexiones residuales no solo en términos de calidad de segmentación sino también de costo computacional, aspecto que adquiere especial relevancia en contextos con recursos limitados.

3. Limitaciones del estudio

A pesar de los resultados favorables, es importante reconocer las limitaciones del estudio:

- Los modelos fueron entrenados y evaluados exclusivamente sobre dos datasets públicos (SIPAKMED y Mendeley LBC). Si bien estos conjuntos son ampliamente utilizados en la literatura, no representan la totalidad de las condiciones de adquisición que se encontrarían en un entorno clínico real.
- El pipeline de preprocesamiento no incorpora técnicas de normalización de tinción (*stain normalization*), lo cual constituye una limitación relevante para la transferibilidad clínica del sistema. Las variaciones en los protocolos de tinción entre laboratorios locales introducen diferencias sistemáticas en la apariencia de las muestras que pueden degradar el desempeño de los modelos cuando se aplican fuera del dominio de entrenamiento.
- El etiquetado manual de las máscaras de segmentación, aunque fue realizado siguiendo las convenciones del sistema Bethesda, no contó con una validación cruzada por parte de un segundo citopatólogo, lo que introduce un posible sesgo en las anotaciones de referencia.
- La evaluación de YOLOv8 se limitó a la variante nano. Es posible que variantes con mayor capacidad (medium, large) hubieran ofrecido un desempeño más competitivo, aunque a costa de un mayor riesgo de sobreajuste dado el tamaño moderado de los datasets.
- No se realizó una evaluación clínica formal con especialistas en citología, lo cual habría permitido contrastar las métricas computacionales con la pertinencia diagnóstica percibida por el personal médico.

4. Trabajo futuro

Los resultados y las limitaciones identificadas abren varias líneas de investigación que podrían fortalecer y extender el alcance del sistema propuesto:

- **Validación con datos clínicos reales:** evaluar el pipeline y los modelos sobre imágenes provenientes de laboratorios clínicos locales, con condiciones de adquisición no controladas, para medir la capacidad de generalización del sistema en un entorno de tamizaje real.
- **Revisión por experto clínico:** someter las segmentaciones producidas por los modelos a la evaluación de un citopatólogo o cancerólogo, con el fin de establecer umbrales mínimos de desempeño aceptables para su uso como herramienta de apoyo al diagnóstico.

- **Exploración de arquitecturas adicionales:** evaluar modelos más recientes como Attention U-Net y arquitecturas basadas en *Vision Transformers* (ViT). En particular, los resultados del modelo U-Cervix (baseline) revelan que la arquitectura U-Net clásica presenta dificultades para delimitar con precisión los contornos celulares en regiones de bajo contraste, lo que se refleja en un mIoU de apenas 55.8 %. Este comportamiento es atribuible al campo receptivo local y fijo de las convoluciones estándar: cada neurona opera sobre una ventana de tamaño $k \times k$, lo que limita su capacidad para integrar información contextual de largo alcance necesaria para resolver ambigüedades en zonas de transición entre la célula y el fondo.

Los *Vision Transformers* abordan esta limitación mediante el mecanismo de *self-attention*, cuya formulación permite a cada *patch* de la imagen atender simultáneamente a todos los demás. Dado un conjunto de *patches* representados como vectores $\mathbf{x}_i \in \mathbb{R}^d$, la atención se calcula como:

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d_k}}\right) \mathbf{V},$$

donde $\mathbf{Q} = \mathbf{X}\mathbf{W}_Q$, $\mathbf{K} = \mathbf{X}\mathbf{W}_K$ y $\mathbf{V} = \mathbf{X}\mathbf{W}_V$ son las proyecciones lineales de consulta, clave y valor, respectivamente, y d_k es la dimensión de las claves. La operación $\text{softmax}(\mathbf{Q}\mathbf{K}^\top/\sqrt{d_k})$ produce una matriz de pesos de atención $\mathbf{A} \in \mathbb{R}^{N \times N}$, donde N es el número total de *patches*. Cada entrada a_{ij} cuantifica la relevancia del *patch* j para la representación del *patch* i , lo que permite que un píxel en una región de bajo contraste incorpore información de regiones distantes con mayor contraste para refinar su clasificación. En contraste, una convolución 3×3 solo accede a 9 vecinos inmediatos, y aunque el apilamiento de capas amplía el campo receptivo teórico, la contribución efectiva de píxeles lejanos decae exponencialmente.

Arquitecturas híbridas como TransUNet combinan un encoder basado en ViT con un decoder convolucional tipo U-Net, preservando la resolución espacial necesaria para la segmentación densa mientras aprovechan el contexto global del *self-attention*. Esta combinación podría resolver directamente las limitaciones de contraste y delimitación de bordes observadas en los resultados del presente estudio, especialmente en las citologías donde la transición entre el citoplasma y el fondo presenta gradientes de intensidad sutiles.

- **Normalización de tinción para transferibilidad clínica:** integrar técnicas de normalización de tinción (*stain normalization*), como los métodos de Macenko o Vahadane, como etapa obligatoria del pipeline de preprocesamiento previo al despliegue en laboratorios locales. Las variaciones en los protocolos de tinción entre instituciones representan la principal barrera para la transferibilidad clínica del sistema, y su mitigación es un requisito indispensable para garantizar que los modelos mantengan su desempeño fuera del dominio de entrenamiento.

- **Ampliación del esquema de preprocesamiento:** investigar técnicas complementarias como la deconvolución de color y operaciones morfológicas avanzadas, específicamente diseñadas para imágenes citológicas, con el fin de mejorar la delimitación de las estructuras celulares y nucleares.
- **Despliegue como herramienta de asistencia:** desarrollar una interfaz que permita al personal clínico cargar imágenes y obtener segmentaciones en tiempo real, como primer paso hacia la integración del sistema en flujos de trabajo de tamizaje cervical.



Anexos

5. Configuración del Entorno de Software

A continuación se presenta el listado completo de bibliotecas y dependencias utilizadas en el entorno de desarrollo del proyecto, organizadas por categoría funcional.

Cuadro 10.1: Frameworks de aprendizaje profundo

Biblioteca	Versión	Uso principal
tensorflow	2.20.0	Framework principal de aprendizaje profundo para construir y entrenar redes neuronales
keras	3.13.2	API de alto nivel para definir, compilar y entrenar modelos sobre TensorFlow
torch	2.5.1+cu121	Framework PyTorch con soporte GPU CUDA 12.1 para deep learning
torchvision	0.20.1+cu121	Datasets, transformaciones y modelos preentrenados de visión para PyTorch
torchaudio	2.5.1+cu121	Módulos de carga, transformación y modelos de audio para PyTorch
tensorboard	2.20.0	Visualización de métricas, grafos y resultados del entrenamiento
tensorboard-data-server	0.7.2	Servidor backend de alto rendimiento para servir datos a TensorBoard
h5py	3.15.1	Interfaz para archivos HDF5; usado para guardar y cargar modelos Keras

Cuadro 10.2: Dependencias internas de TensorFlow y Keras

Biblioteca	Versión	Uso principal
absl-py	2.4.0	Utilidades de Google (flags, logging) requeridas por TensorFlow
gast	0.7.0	Manejo genérico de AST de Python; dependencia interna de TensorFlow
google-pasta	0.2.0	Análisis y modificación de código Python; dependencia de TensorFlow
termcolor	3.3.0	Salida de texto coloreado en terminal; usada por TensorFlow para logging
wrapt	2.0.1	Utilidad para decoradores y wrappers; dependencia de TensorFlow
astunparse	1.6.3	Conversión de AST a código fuente; dependencia interna de TensorFlow
opt_einsum	3.4.0	Optimización de contracciones de tensores (einsum) para TensorFlow y Keras
ml_dtypes	0.5.4	Tipos de datos de ML (bfloat16, float8) para NumPy y TensorFlow
flatbuffers	25.12.19	Serialización eficiente en memoria; usada por TensorFlow Lite
libclang	18.1.1	Bindings para libclang; usada por TensorFlow para análisis de código C/C++
namex	0.1.0	Utilidad de Keras para exportar espacios de nombres de paquetes
optree	0.18.0	Manipulación de estructuras PyTree para operaciones de tensores en Keras
lark	1.3.1	Parser basado en gramáticas Earley/LALR; dependencia de TensorFlow y SymPy

5. Configuración del Entorno de Software

Cuadro 10.3: Visión por computadora

Biblioteca	Versión	Uso principal
opencv-python	4.13.0.90	Procesamiento y análisis de imágenes y video; biblioteca principal de visión
pillow	12.1.0	Manipulación de imágenes: carga, redimensionado y conversión de formatos
segment-anything	1.0	Modelo SAM de Meta para segmentación automática de objetos en imágenes
ultralytics	8.4.19	Framework YOLO para detección, segmentación y clasificación en tiempo real
ultralytics-thop	2.0.18	Cálculo de FLOPs y parámetros de modelos PyTorch (dependencia de Ultralytics)
contourpy	1.3.3	Generación de contornos 2D a partir de datos en cuadrículas; dependencia de Matplotlib

Cuadro 10.4: Ciencia de datos y cómputo científico

Biblioteca	Versión	Uso principal
numpy	2.4.1	Computación numérica con arreglos N-dimensionales; base del ecosistema científico
scipy	1.17.0	Algoritmos científicos: integración, optimización, álgebra lineal y estadística
scikit-learn	1.8.0	Aprendizaje automático clásico: clasificación, regresión, clustering y métricas
polars	1.38.1	DataFrame de alto rendimiento para manipulación de datos tabulares a gran escala
polars-runtime-32	1.38.1	Runtime de 32 bits de Polars para compatibilidad en entornos con esa arquitectura
matplotlib	3.10.8	Visualización de datos 2D: gráficas, histogramas y mapas de calor
sympy	1.13.1	Matemática simbólica: álgebra, cálculo y simplificación de expresiones
mpmath	1.3.0	Aritmética de punto flotante de precisión arbitraria; dependencia de SymPy
networkx	3.6.1	Creación y análisis de grafos y redes; dependencia de PyTorch
joblib	1.5.3	Paralelización y caché de resultados; backend de scikit-learn
threadpoolctl	3.6.0	Control del número de hilos en pools de OpenBLAS/MKL; usado por scikit-learn

5. Configuración del Entorno de Software

Cuadro 10.5: Google APIs y protocolos de comunicación

Biblioteca	Versión	Uso principal
google-api-core	2.29.0	Núcleo común para bibliotecas cliente de Google: reintentos y transporte
google-api-python-client	2.188.0	Cliente Python para las APIs REST de Google (Drive, Sheets, etc.)
google-auth	2.48.0	Autenticación con Google: credenciales, tokens OAuth2 y cuentas de servicio
google-auth-httpplib2	0.3.0	Adaptador de transporte HTTP basado en httpplib2 para google-auth
google-auth-oauthlib	1.2.4	Integración de google-auth con oauthlib para flujos OAuth 2.0
googleapis-common-protos	1.72.0	Definiciones Protobuf comunes compartidas por las APIs de Google
grpcio	1.76.0	Implementación Python de gRPC para comunicación con servicios de Google
proto-plus	1.27.0	Wrapper de alto nivel sobre protobuf para el cliente de Google APIs
protobuf	6.33.5	Serialización con Protocol Buffers; usado por TensorFlow y Google APIs
httpplib2	0.31.2	Cliente HTTP con caché y autenticación; usado por google-auth
uritemplate	4.2.0	Expansión de plantillas URI (RFC 6570); dependencia del cliente de Google APIs



Cuadro 10.6: Entorno Jupyter y notebooks interactivos (Parte 1)

Biblioteca	Versión	Uso principal
jupyterlab	4.5.3	IDE web de nueva generación para notebooks Jupyter con soporte de extensiones
notebook	7.5.3	Interfaz clásica de Jupyter Notebook para desarrollo interactivo
jupyter_server	2.17.0	Servidor backend compartido por JupyterLab y Jupyter Notebook
jupyter_client	8.8.0	Gestión de la comunicación entre el frontend de Jupyter y los kernels
jupyter_core	5.9.1	Configuración base y utilidades compartidas por todos los componentes Jupyter
ipykernel	7.1.0	Kernel de IPython para Jupyter; ejecuta código Python en los notebooks
ipython	9.9.0	Shell interactivo de Python con autocompletado, historial y funciones mágicas
nbformat	5.10.4	Definición del formato <code>.ipynb</code> y validación de notebooks
nbclient	0.10.4	Ejecución de notebooks de Jupyter de forma programática
nbconvert	7.17.0	Conversión de notebooks a HTML, PDF, scripts Python y otros formatos
jupyterlab_server	2.28.0	Servidor de extensiones y aplicaciones para JupyterLab
jupyter-lsp	2.3.0	Integración del Language Server Protocol en JupyterLab
jupyter-events	0.12.0	Sistema de eventos y logging estructurado para el servidor Jupyter

5. Configuración del Entorno de Software

Cuadro 10.7: Entorno Jupyter y notebooks interactivos (Parte 2)

Biblioteca	Versión	Uso principal
jupyter_server_terminals	0.5.4	Soporte de terminales interactivas en el servidor Jupyter
notebook_shim	0.2.4	Capa de compatibilidad entre la interfaz clásica y el nuevo servidor Jupyter
comm	0.2.3	API estándar para comunicación bidireccional kernel-frontend en Jupyter
traitlets	5.14.3	Sistema de configuración con validación de tipos; base de IPython y Jupyter
pyzmq	27.1.0	Bindings ZeroMQ; transporte de mensajes entre kernel y frontend de Jupyter
tornado	6.5.4	Framework web asíncrono; servidor HTTP subyacente de Jupyter
terminado	0.18.1	Terminales web basadas en tornado para Jupyter
debugpy	1.8.20	Adaptador de depuración Python (DAP) para JupyterLab y VS Code
Send2Trash	2.1.0	Envío de archivos a la papelera; usado por el gestor de archivos de Jupyter
prometheus_client	0.24.1	Exposición de métricas Prometheus; usado por el servidor Jupyter para monitoreo
nest-asyncio	1.6.0	Anidamiento de bucles asyncio; necesario en notebooks con IPython
matplotlib-inline	0.2.1	Renderizado en línea de gráficas Matplotlib dentro de notebooks Jupyter
pywinpty	3.0.2	Emulación de pseudo-terminal en Windows; requerida por terminado

Cuadro 10.8: HTTP, redes y comunicación asíncrona

Biblioteca	Versión	Uso principal
requests	2.32.5	Cliente HTTP sincrónico de alto nivel; estándar de facto para peticiones HTTP
httpx	0.28.1	Cliente HTTP moderno con soporte sync/async e HTTP/2
httpcore	1.0.9	Capa de transporte HTTP de bajo nivel; backend de httpx
anyio	4.12.1	Abstracción async compatible con asyncio y trio; base de httpx
h11	0.16.0	Implementación pura de Python del protocolo HTTP/1.1; backend de httpcore
urllib3	2.6.3	Pool de conexiones HTTP y manejo de reintentos; backend de requests
certifi	2026.1.4	Bundle de certificados CA raíz de Mozilla para validación SSL/TLS
idna	3.11	Soporte de nombres de dominio internacionalizados (IDNA 2008)
charset-normalizer	3.4.4	Detección automática del encoding de texto en respuestas HTTP
websocket-client	1.9.0	Cliente WebSocket sincrónico; usado por Jupyter y otras herramientas
async-lru	2.1.0	Caché LRU para funciones asíncronas; dependencia de JupyterLab



5. Configuración del Entorno de Software

Cuadro 10.9: Seguridad, criptografía y autenticación

Biblioteca	Versión	Uso principal
cryptography	46.0.4	Primitivas criptográficas de alto y bajo nivel (AES, RSA, TLS)
argon2-cffi	25.1.0	Implementación del algoritmo de hash de contraseñas Argon2
argon2-cffi-bindings	25.1.0	Bindings CFFI de bajo nivel para la librería C de Argon2
cffi	2.0.0	Foreign Function Interface para llamar a código C desde Python
pycparser	3.0	Parser de C en Python puro; dependencia de cffi
pyasn1	0.6.2	Codificación/decodificación ASN.1; usada para certificados X.509
pyasn1-modules	0.4.2	Módulos ASN.1 predefinidos (PKIX, PKCS, RFC) sobre pyasn1
rsa	4.9.1	Implementación pura del algoritmo RSA; usada por google-auth para JWT
oauthlib	3.3.1	Implementación del estándar OAuth 1 y OAuth 2
requests-oauthlib	2.0.0	Integración de oauthlib con requests para autenticación OAuth



Cuadro 10.10: Formatos de datos y serialización

Biblioteca	Versión	Uso principal
PyYAML	6.0.3	Lectura y escritura de archivos YAML para configuración de proyectos
jsonschema	4.26.0	Validación de documentos JSON contra esquemas JSON Schema
jsonschema-specifications	2025.9.1	Especificaciones de los dialectos JSON Schema (2019-09, 2020-12)
jsonpointer	3.0.0	Implementación de JSON Pointer (RFC 6901) para navegar documentos JSON
fastjsonschema	2.21.2	Validación ultra-rápida de JSON Schema mediante generación de código
referencing	0.37.0	Motor de resolución de \$ref en esquemas JSON; dependencia de jsonschema
rpds-py	0.30.0	Estructuras de datos persistentes basadas en Rust; base de referencing
attrs	25.4.0	Definición de clases Python con validación automática de atributos
python-json-logger	4.0.0	Formateo de logs en JSON estructurado para sistemas de observabilidad
json5	0.13.0	Superconjunto de JSON con comentarios y sintaxis flexible; usado por JupyterLab

5. Configuración del Entorno de Software

Cuadro 10.11: Procesamiento web, HTML y plantillas

Biblioteca	Versión	Uso principal
beautifulsoup4	4.14.3	Parsing y extracción de datos de HTML/XML; web scraping
soupsieve	2.8.3	Selectores CSS para BeautifulSoup4
bleach	6.3.0	Sanitización de HTML: elimina etiquetas peligrosas para prevenir XSS
Jinja2	3.1.6	Motor de plantillas web; usado por nbconvert, Flask y JupyterLab
MarkupSafe	3.0.3	Manejo seguro de strings HTML con escape automático; dependencia de Jinja2
Markdown	3.10.1	Conversión de texto Markdown a HTML; dependencia de TensorBoard
markdown-it-py	4.0.0	Parser Markdown de alta fidelidad en Python puro; dependencia de rich
mdurl	0.1.2	Normalización de URLs para markdown-it-py
mistune	3.2.0	Parser Markdown rápido; usado por nbconvert para renderizar celdas
tinycss2	1.4.0	Parser de CSS de bajo nivel; dependencia de nbconvert
defusedxml	0.7.1	Versiones seguras de los módulos XML de Python contra ataques de entidad
pandocfilters	1.5.1	Utilidades para filtros de Pandoc en Python; usado por nbconvert
Werkzeug	3.1.5	Librería WSGI con utilidades para aplicaciones web Python; base de Flask
webencodings	0.5.1	Decodificación de encodings según el estándar HTML5; dependencia de bleach
webcolors	25.10.0	Conversión entre nombres de colores CSS y representaciones hexadecimal/RGB



Cuadro 10.12: Análisis de código y depuración (IPython)

Biblioteca	Versión	Uso principal
jedi	0.19.2	Motor de autocompletado y análisis estático; backend de IPython y editores
parso	0.8.5	Parser de Python tolerante a errores de sintaxis; base de jedi
Pygments	2.19.2	Resaltado de sintaxis para más de 300 lenguajes; usado por IPython y rich
prompt_toolkit	3.0.52	Interfaces de línea de comandos interactivas; base del REPL de IPython
asttokens	3.0.1	Anotación del AST de Python con posiciones de tokens en el código fuente
executing	2.2.1	Introspección del código en ejecución; dependencia de stack-data
pure_eval	0.2.3	Evaluación segura de expresiones Python sin efectos secundarios
stack-data	0.6.3	Información enriquecida de trazas de pila para mejores mensajes de error
decorator	5.2.1	Simplificación de la escritura de decoradores preservando la firma
ipython_pygments_lexers	1.1.1	Lexers de Pygments adicionales para IPython (consola, trazas de error)
wcwidth	0.5.2	Cálculo del ancho Unicode de caracteres para alineación en terminales



5. Configuración del Entorno de Software

Cuadro 10.13: Kaggle y acceso a datos externos

Biblioteca	Versión	Uso principal
kagglehub	0.4.2	Descarga de datasets y modelos desde Kaggle Hub con caché local automático
kagglesdk	0.1.15	SDK oficial de Kaggle para interactuar con la API: datasets y competiciones
fsspec	2025.12.0	Abstracción de sistema de archivos (local, S3, GCS, HTTP); dependencia de PyTorch
filelock	3.20.0	Bloqueo de archivos multiplataforma para sincronización de acceso concurrente
tqdm	4.67.1	Barras de progreso para bucles y CLI; usado en descarga de datos y entrenamiento

Cuadro 10.14: Utilidades generales y compatibilidad

Biblioteca	Versión	Uso principal
rich	14.3.1	Salida enriquecida en terminal: colores, tablas, Markdown y progreso
colorama	0.4.6	Soporte de secuencias ANSI para colores en terminal en Windows
packaging	26.0	Análisis y comparación de versiones PEP 440 de paquetes Python
platformdirs	4.5.1	Localización de directorios estándar del sistema (config, datos, caché)
psutil	7.2.2	Información del sistema: CPU, memoria, procesos, disco y red
typing_extensions	4.15.0	Backport de anotaciones de tipos recientes a versiones anteriores de Python
six	1.17.0	Capa de compatibilidad Python 2/3; dependencia legacy de varios paquetes
overrides	7.7.0	Decorador <code>@override</code> para verificar correctamente la herencia de métodos
arrow	1.4.0	Manejo amigable de fechas y horas con zona horaria
python-dateutil	2.9.0.post0	Extensiones avanzadas a datetime: parseo flexible y recurrencias
tzdata	2025.3	Base de datos de zonas horarias IANA para Python
babel	2.17.0	Internacionalización: fechas, números y monedas localizados
pyparsing	3.3.2	Construcción de gramáticas y parsers en Python; dependencia de Matplotlib



Bibliografía

- [1] A. Jemal, F. Bray, M. M. Center, J. Ferlay, E. Ward y D. Forman, «Global cancer statistics,» *CA: A Cancer Journal for Clinicians*, vol. 61, n.º 2, págs. 69-90, 2012. DOI: [10.3322/caac.20107](https://doi.org/10.3322/caac.20107)
- [2] K. Zuiderveld, «Contrast Limited Adaptive Histogram Equalization,» en *Graphics Gems IV*, Academic Press Professional, Inc., 1994, págs. 474-485.
- [3] V. Chandola, A. Banerjee y V. Kumar, «Anomaly detection: A survey,» *ACM Computing Surveys (CSUR)*, vol. 41, n.º 3, págs. 1-58, 2009. DOI: [10.1145/1541880.1541882](https://doi.org/10.1145/1541880.1541882)
- [4] C. Tomasi y R. Manduchi, «Bilateral Filtering for Gray and Color Images,» págs. 839-846, 1998. DOI: [10.1109/ICCV.1998.710815](https://doi.org/10.1109/ICCV.1998.710815)
- [5] R. C. Gonzalez y R. E. Woods, *Digital Image Processing*, 3rd. Prentice Hall, 2008.
- [6] I. Goodfellow, Y. Bengio y A. Courville, *Deep Learning*. MIT Press, 2016.
- [7] O. Ronneberger, P. Fischer y T. Brox, «U-Net: Convolutional Networks for Biomedical Image Segmentation,» en *Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015*, ép. Lecture Notes in Computer Science, vol. 9351, Springer, 2015, págs. 234-241. DOI: [10.1007/978-3-319-24574-4_28](https://doi.org/10.1007/978-3-319-24574-4_28)
- [8] P. Jaccard, «The Distribution of the Flora in the Alpine Zone,» *New Phytologist*, vol. 11, n.º 2, págs. 37-50, 1912. DOI: [10.1111/j.1469-8137.1912.tb05611.x](https://doi.org/10.1111/j.1469-8137.1912.tb05611.x)
- [9] D. M. W. Powers, «Evaluation: From Precision, Recall and F-Measure to ROC, Informedness, Markedness and Correlation,» *Journal of Machine Learning Technologies*, vol. 2, n.º 1, págs. 37-63, 2011.
- [10] J. A. Hanley y B. J. McNeil, «The Meaning and Use of the Area under a Receiver Operating Characteristic (ROC) Curve,» *Radiology*, vol. 143, n.º 1, págs. 29-36, 1982. DOI: [10.1148/radiology.143.1.7063747](https://doi.org/10.1148/radiology.143.1.7063747)
- [11] Commission Internationale de l'Éclairage, *Recommendations on Uniform Color Spaces, Color-Difference Equations, Psychometric Color Terms*, CIE Publication 15 (E-1.3.1), 1978.
- [12] A. Buades, B. Coll y J.-M. Morel, «A Non-Local Algorithm for Image Denoising,» *2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR)*, vol. 2, págs. 60-65, 2005. DOI: [10.1109/CVPR.2005.38](https://doi.org/10.1109/CVPR.2005.38)
- [13] Asociación Española para el Estudio del Cáncer de Cuello Uterino, *Guía de prevención secundaria del cáncer de cuello de útero*, <https://www.aepcc.org/wp-content/uploads/2022/11/Guia-Prevencion-cancer-cervix-2022.pdf>, [Online; accessed 05-June-2025], 2022.

- [14] Instituto Nacional del Cáncer (NCI), *Detección del cáncer de cuello uterino*, <https://www.cancer.gov/espanol/tipos/cuello-uterino/deteccion>, Accedido el 4 de julio de 2025, 2025.
- [15] National Cancer Institute, *Investigadores crean planteamiento de IA para exámenes de detección de cáncer cervical*, <https://www.cancer.gov/espanol/noticias/comunicados-de-prensa/2019/aprendizaje-profundo-cancer-cuello-uterino-examen-de-deteccion>, [Online; accessed 05-June-2025], 2019.
- [16] S. K. et al., «Clasificación de cáncer cervical usando redes neuronales convolucionales y transferencia de aprendizaje,» *Revista Latinoamericana de Computación*, vol. 10, n.º 1, págs. 100-110, 2021.
- [17] H. Zhang y X. Wang, «Deep learning approaches for cervical cancer diagnosis,» *IEEE Transactions on Medical Imaging*, vol. 41, n.º 5, págs. 1234-1245, 2022. DOI: [10.1109/TMI.2022.3145678](https://doi.org/10.1109/TMI.2022.3145678)
- [18] S. Ghosh, H. Basak, N. Das y S. Saha, «Fuzzy Rank-Based Ensemble Model for Classification of Cervical Cancer Using Pap Smear Images,» *Biomedical Signal Processing and Control*, vol. 71, pág. 103217, feb. de 2022. DOI: [10.1016/j.bspc.2021.103217](https://doi.org/10.1016/j.bspc.2021.103217)
- [19] H. Basak, R. Kundu, S. Chakraborty y N. Das, *Cervical Cytology Classification Using PCA & GWO Enhanced Deep Features Selection*, <https://paperswithcode.com/paper/cervical-cytology-classification-using-pca>, Accessed: Jun. 6, 2025, 2021.
- [20] R. Pramanik, M. Sengupta y S. Sural, *Fuzzy Distance-Based Ensemble Approach for Cervical Cancer Detection Using Pap Smear Images*, <https://github.com/rishavpramanik/CervicalFuzzyDistanceEnsemble>, Accessed: Jun. 6, 2025, 2022.
- [21] M. K. Islam, M. N. Uddin, M. A. Rahman, M. A. R. Akhand y M. M. Rahman, «DeepCervix: A Deep Hybrid Feature Fusion Approach for the Classification of Cervical Cell Images,» *Computers in Biology and Medicine*, vol. 136, pág. 104649, sep. de 2021. DOI: [10.1016/j.combiomed.2021.104649](https://doi.org/10.1016/j.combiomed.2021.104649)
- [22] Y. T. Marante e Y. H. Victor, *Evaluación y clasificación de las imágenes de células del cérvix usando rasgos de texturas y morfológicos*, 2022.
- [23] R. A. Salinas Franco, G. P. Coelho, P. S. Martins y M. A. de Carvalho, «Descriptores MAC en la detección temprana del cáncer cervical usando técnicas de procesamiento de imágenes,» *Revista Cubana de Ciencias Informáticas*, vol. 16, n.º 1, págs. 1-17, 2022, ISSN: 2227-1899.
- [24] D. A. Ciro Marín, S. A. Hurtado Soto y L. M. Chacón Rivera, *Identificación de anomalías de las células cervicales mediante inteligencia artificial*, Bogotá, Colombia, 2024.

- [25] M. A. Bravo-Ortíz, H. B. Arteaga-Arteaga, K. R. Tabares-Soto, J. I. Padilla-Buriticá y S. Orozco-Arias, «Clasificación de cáncer cervical usando redes neuronales convolucionales, transferencia de aprendizaje y aumento de datos,» *Revista EIA*, vol. 18, n.º 35, págs. 1-17, 2021. DOI: [10.24050/reia.v18i35.1462](https://doi.org/10.24050/reia.v18i35.1462)
- [26] C. M. Jesus, J. E. Vilchez Chamane y L. Chamane, *Análisis de algoritmos de aprendizaje automático para la detección de cáncer de cuello uterino utilizando imágenes de Papanicolaou*, Disponible en: <https://hdl.handle.net/20.500.12802/13555>, 2024.
- [27] E. R. Muñoz, «Redes neuronales convolucionales profundas con transferencia de aprendizaje para la detección y clasificación automatizada de tumores en imágenes de tomosíntesis,» Tesis de Maestría, Tesis de mtría., Instituto Nacional de Astrofísica, Óptica y Electrónica, 2022.
- [28] World Health Organization, *Cervical Cancer Fact Sheet*, <https://www.who.int/news-room/fact-sheets/detail/cervical-cancer>, [Online; accessed 05-June-2025], 2023.
- [29] N. Muñoz et al., «Epidemiologic Classification of Human Papillomavirus Types Associated with Cervical Cancer,» *New England Journal of Medicine*, vol. 348, n.º 6, págs. 518-527, 2003. DOI: [10.1056/NEJMoa021641](https://doi.org/10.1056/NEJMoa021641)
- [30] N. Bhatla et al., «Revised FIGO Staging for Carcinoma of the Cervix Uteri,» *International Journal of Gynecology & Obstetrics*, vol. 145, n.º 1, págs. 129-135, 2019. DOI: [10.1002/ijgo.12749](https://doi.org/10.1002/ijgo.12749)
- [31] K. Nanda et al., «Accuracy of the Papanicolaou Test in Diagnosing Cervical Neoplasia: A Meta-Analysis,» *Annals of Internal Medicine*, vol. 132, n.º 10, págs. 810-819, 2000. DOI: [10.7326/0003-4819-132-10-200005160-00009](https://doi.org/10.7326/0003-4819-132-10-200005160-00009)
- [32] R. Nayar y D. C. Wilbur, *The Bethesda System for Reporting Cervical Cytology: Definitions, Criteria, and Explanatory Notes*, 3.^a ed. New York: Springer, 2015. DOI: [10.1007/978-3-319-11074-5](https://doi.org/10.1007/978-3-319-11074-5)
- [33] R. C. Gonzalez y R. E. Woods, *Digital Image Processing*, 4.^a ed. New York: Pearson, 2018.
- [34] C. Shorten y T. M. Khoshgoftaar, «A Survey on Image Data Augmentation for Deep Learning,» *Journal of Big Data*, vol. 6, n.º 1, pág. 60, 2019. DOI: [10.1186/s40537-019-0197-0](https://doi.org/10.1186/s40537-019-0197-0)
- [35] V. N. Vapnik, *Statistical Learning Theory*. New York: Wiley-Interscience, 1998.
- [36] C. Cortes y V. Vapnik, «Support-Vector Networks,» *Machine Learning*, vol. 20, n.º 3, págs. 273-297, 1995. DOI: [10.1007/BF00994018](https://doi.org/10.1007/BF00994018)
- [37] J. Pearl, *Probabilistic Reasoning in Intelligent Systems: Networks of Plausible Inference*. San Francisco: Morgan Kaufmann, 1988.

- [38] Y. LeCun, L. Bottou, Y. Bengio y P. Haffner, «Gradient-Based Learning Applied to Document Recognition,» *Proceedings of the IEEE*, vol. 86, n.º 11, págs. 2278-2324, 1998. DOI: [10.1109/5.726791](https://doi.org/10.1109/5.726791)
- [39] S. Ioffe y C. Szegedy, «Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift,» en *Proceedings of the 32nd International Conference on Machine Learning (ICML)*, ép. Proceedings of Machine Learning Research, vol. 37, PMLR, 2015, págs. 448-456. DOI: [10.48550/arXiv.1502.03167](https://doi.org/10.48550/arXiv.1502.03167)
- [40] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever y R. Salakhutdinov, «Dropout: A Simple Way to Prevent Neural Networks from Overfitting,» *Journal of Machine Learning Research*, vol. 15, n.º 1, págs. 1929-1958, 2014.
- [41] J. Tompson, R. Goroshin, A. Jain, Y. LeCun y C. Bregler, «Efficient Object Localization Using Convolutional Networks,» en *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2015, págs. 648-656. DOI: [10.1109/CVPR.2015.7298664](https://doi.org/10.1109/CVPR.2015.7298664)
- [42] S. J. Pan y Q. Yang, «A Survey on Transfer Learning,» *IEEE Transactions on Knowledge and Data Engineering*, vol. 22, n.º 10, págs. 1345-1359, 2010. DOI: [10.1109/TKDE.2009.191](https://doi.org/10.1109/TKDE.2009.191)
- [43] M. Raghu, C. Zhang, J. Kleinberg y S. Bengio, «Transfusion: Understanding Transfer Learning for Medical Imaging,» en *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 32, Curran Associates, 2019, págs. 3342-3352. arXiv: [1902.07208](https://arxiv.org/abs/1902.07208).
- [44] T. G. Dietterich, «Ensemble Methods in Machine Learning,» en *Proceedings of the 1st International Workshop on Multiple Classifier Systems (MCS)*, ép. Lecture Notes in Computer Science, vol. 1857, Springer, 2000, págs. 1-15. DOI: [10.1007/3-540-45014-9_1](https://doi.org/10.1007/3-540-45014-9_1)
- [45] L. A. Zadeh, «Fuzzy Sets,» *Information and Control*, vol. 8, n.º 3, págs. 338-353, 1965. DOI: [10.1016/S0019-9958\(65\)90241-X](https://doi.org/10.1016/S0019-9958(65)90241-X)
- [46] I. T. Jolliffe, *Principal Component Analysis*, 2.^a ed. New York: Springer, 2002. DOI: [10.1007/b98835](https://doi.org/10.1007/b98835)
- [47] S. Mirjalili, S. M. Mirjalili y A. Lewis, «Grey Wolf Optimizer,» *Advances in Engineering Software*, vol. 69, págs. 46-61, 2014. DOI: [10.1016/j.advengsoft.2013.12.007](https://doi.org/10.1016/j.advengsoft.2013.12.007)
- [48] M. E. Plissiti, P. Dimitrakopoulos, G. Sfikas, C. Nikou, O. Krikoni y A. Charchanti, «SIPaKMeD: A New Dataset for Feature and Image Based Classification of Normal and Pathological Cervical Cells in Pap Smear Images,» en *2018 25th IEEE International Conference on Image Processing (ICIP)*, IEEE, 2018, págs. 3144-3148. DOI: [10.1109/ICIP.2018.8451588](https://doi.org/10.1109/ICIP.2018.8451588)
- [49] J. Jantzen, J. Norup, G. Dounias y B. Bjerregaard, «Pap-Smear Benchmark Data for Pattern Classification,» en *Proceedings of the Nature Inspired Smart Information Systems (NiSIS 2005)*, 2005, págs. 1-9.

- [50] A. Smith y L. Johnson, «Screening methods for early detection of cervical cancer,» *Journal of Medical Screening*, vol. 26, n.º 1, págs. 12-20, 2019. DOI: [10.1177/0969141319876543](https://doi.org/10.1177/0969141319876543)
- [51] M. García y R. López, «Challenges in manual analysis of cervical cytology images,» *International Journal of Cytology*, vol. 34, n.º 3, págs. 45-53, 2020.
- [52] Y. L. et al., «Automated segmentation and classification of cervical cells: A review,» *Computers in Biology and Medicine*, vol. 130, pág. 104230, 2021. DOI: [10.1016/j.compbiomed.2021.104230](https://doi.org/10.1016/j.compbiomed.2021.104230)
- [53] L. A. Molina, «Prevención del cáncer de cuello uterino en Colombia: entre la cobertura y la calidad,» *Revista Cáncer-Colombia*, vol. 14, n.º 2, págs. 47-50, 2020, Accedido: 6-jul-2025. dirección: <https://www.revistacancercol.org/index.php/cancer/article/view/259/112>
- [54] E. Hussain, L. B. Mahanta, C. R. Das y R. K. Talukdar, *Liquid based cytology pap smear images for multi-class diagnosis of cervical cancer*, ver. 4, 2020. DOI: [10.17632/zddtpgzv63.4](https://doi.org/10.17632/zddtpgzv63.4) dirección: <https://data.mendeley.com/datasets/zddtpgzv63/4>
- [55] K. Simonyan y A. Zisserman, «Very Deep Convolutional Networks for Large-Scale Image Recognition,» en *3rd International Conference on Learning Representations (ICLR 2015)*, 2015. arXiv: [1409.1556](https://arxiv.org/abs/1409.1556) [cs.CV].
- [56] D. P. Kingma y J. L. Ba, «Adam: A Method for Stochastic Optimization,» *arXiv preprint arXiv:1412.6980*, 2014. DOI: [10.48550/arXiv.1412.6980](https://doi.org/10.48550/arXiv.1412.6980) arXiv: [1412.6980](https://arxiv.org/abs/1412.6980) [cs.LG].
- [57] K. He, X. Zhang, S. Ren y J. Sun, «Deep Residual Learning for Image Recognition,» en *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, Las Vegas, NV, jun. de 2016, págs. 770-778. DOI: [10.1109/CVPR.2016.90](https://doi.org/10.1109/CVPR.2016.90)
- [58] L. Xiang, Y. Li, W. Lin, Q. Wang y D. Shen, «Unpaired Deep Cross-Modality Synthesis with Fast Training,» en *Deep Learning in Medical Image Analysis and Multimodal Learning for Clinical Decision Support*. Springer International Publishing, 2018, págs. 155-164, ISBN: 9783030008895. DOI: [10.1007/978-3-030-00889-5_18](https://doi.org/10.1007/978-3-030-00889-5_18) dirección: http://dx.doi.org/10.1007/978-3-030-00889-5_18
- [59] G. Jocher, A. Chaurasia y J. Qiu, *Ultralytics YOLO*, <https://github.com/ultralytics/ultralytics>, ver. 8.0.0, 2023. dirección: <https://github.com/ultralytics/ultralytics>

